

Cadre du modèle et chemin de résolution

Romain R.

Juin 2026

ce rapport fixe un premier cadre et les notations/grandeurs, justifie les premiers choix de résolution/de validation, et justifie le choix des pistes ML pour le closed-loop Stackelberg quand la dimension deviendra un vrai problème. Enfin, il présente les analyses de données actualisées de l'article de Coulomb et al.

1 Projet

Idée du projet : greffer une **politique climatique côté offre** (*Buy Coal !*, Harstad 2012 : une coalition achète des gisements et s'engage à ne pas les exploiter, elle les "gèle") sur un **jeu d'extraction oligopole-frange** (un cartel type OPEP avec pouvoir de marché, face à une frange concurrentielle price-taker). Les données : champs hétérogènes de Rystad.

L'objet final est un **graphe orienté acyclique (DAG)** où chaque *nœud* dicte qui est dans quel bloc (cartel / coalition / frange). Sur un nœud, on résout l'équilibre d'extraction, on lit les payoffs, et on *élague* les nœuds où un membre a une déviation profitable. **La résolution d'un nœud est le cœur du problème** ; le DAG est la structure externe.

2 Notations

- S_t^i : réserves du bloc $i \in \{c, f, k\}$ (cartel, frange, et aussi coalition pour soustraire à l'offre globale) en début de période t .
- x_t^i : extraction. $Q_t = x_t^c + x_t^f$; prix par demande inverse $p_t = P(Q_t)$ (linéaire $\alpha - \beta Q_t$).
- c^i : coût marginal d'extraction (\$/bbl), agrégé par bloc dans un premier temps, mais l'hétérogénéité des coûts s'avère nécessaire quand la coalition offre des contrats.
- $\delta = 1/(1+r)$: actualisation. r commun aux extracteurs (pour la comparabilité avec la littérature) ; pour la coalition, un r_{SCC} potentiellement plus bas.
- intensité carbone, SCC, coût carbone par baril.
- Pour les offres de contrat de la coalition. T_j : transfert de gel du gisement j ; γ : pouvoir de négociation ; A_j : valorisation du gel par la coalition ; R_j : rente de réservation du propriétaire



3 Cadre du jeu et programmes des agents

Hiérarchie des modèles

- *Open-loop* : Trajectoires fixées en $t = 0$. Formellement rejeté car temporellement incohérent (incitations à dévier *ex post*).

- *Nash-Cournot répété* : Décisions simultanées à chaque période. Algébriquement traitable, il garantit la perfection en sous-jeux et constituerait la baseline.
- *Closed-loop Stackelberg (Feedback Markov Perfect)* : Le leader (le cartel) intègre la fonction de réaction state-dependent du follower (la frange, qui joue *après* le leader). Modèle géopolitiquement le plus réaliste, mais exigeant computationnellement.



Malédiction de la dimension

Naivement, le closed-loop souffre de la malédiction de la dimension : discrétiser les réserves de ~ 10 agents en 10 points = 10^{10} **états**, intenable. Si la frange est modélisée comme un agent représentatif (agrégé) *price-taker*, l'espace d'état s'effondre à une dimension faible (S^c, S^f, t). Le problème *closed-loop* est alors soluble exactement, avec de la programmation dynamique. Toutefois, pour que la coalition cible des gisements marginaux spécifiques (avec ses contrats), l'hétérogénéité intra-bloc doit être préservée (ex. : sables bitumineux canadiens (sales, chers) vs brut conventionnel norvégien (plus propre, peu cher). Le scalaire S^f éclate en une matrice d'états individuels et de haute dimension. Les réseaux de neurones (partie 6) s'imposent alors comme nécessaires.

Résolution par induction arrière pour Nash Cournot et closed-loop Stackelberg car l'horizon temporel est fini et cela assure un équilibre crédible à chaque étape (Nash parfait en sous-jeux). C'est possible aussi car le jeu est **markovien (et l'équilibre Markov Perfect)** (seul l'état courant importe dans le programme des agents, et pas l'historique)

Équations de Bellman. Pour la frange (price-taker) :

$$V^f(S_t^f, t) = \max_{0 \leq x^f \leq S_t^f} (p_t - c^f) x^f + \delta V^f(S_t^f - x^f, t+1),$$

dont la forme déroulée est :

$$V^f(S_0^f, 0) = \max_{x_0^f, \dots, x_{T-1}^f} \sum_{t=0}^{T-1} \delta^t (p_t - c^f) x_t^f \quad (\text{sous contraintes de stock}).$$

L'état est (S^f, t) , l'action x^f , la récompense immédiate (ou profit courant) $(p_t - c^f)x^f$, le facteur d'actualisation δ , et V^f est la value function. La FOC est la règle de Hotelling : $p_t - c^f = \delta \partial V^f / \partial S^f$ (d'où émerge la rente de rareté, profit net = coût intertemporel du stock).

Pour le cartel (leader), la valeur dépend aussi du stock de la frange (c'est la dépendance « **feedback** ») :

$$V^c(S_t^c, S_t^f, t) = \max_{0 \leq x^c \leq S_t^c} \left[\Pi^c(x^c, x^{f*}) + \delta V^c(S_t^c - x^c, S_t^f - x^{f*}, t+1) \right]$$

où le profit courant est $\Pi^c = (P(x^c + x^{f*}) - c^c)x^c$ et $x^{f*}(x^c)$ est la meilleure réponse de la frange. Le **programme du cartel est imbriqué** : pour évaluer son payoff pour un x^c candidat, il doit d'abord anticiper la réponse de la frange. Sa FOC, par différentiation de l'équation de Bellman (règle de la chaîne) :

$$P + \underbrace{\theta \frac{\partial P}{\partial x^c} x^c}_{\text{Pouvoir de marché}} - c^c + \underbrace{\left(\frac{\partial P}{\partial x^f} x^c \right) \frac{dx^{f*}}{dx^c}}_{\text{Anticipation (extraction)}} = \delta \frac{\partial V^c}{\partial S^c} + \underbrace{\delta \frac{\partial V^c}{\partial S^f} \frac{dx^{f*}}{dx^c}}_{\text{Anticipation (stock)}}$$

où l'on a introduit $\theta \in [0, 1]$ en facteur du pouvoir de marché pour prendre en compte la collusion imparfaite (Okullo & Reynès).



Le terme de réaction dx^{f*}/dx^c est absent en Nash-Cournot (chacun prend l'action de l'autre comme fixe). Le cartel internalise le programme de la frange en *Stackelberg* : en *reinforcement learning*



(section 6.B), on intégrerait la politique convergée de la frange dans le programme du cartel ; avec des *Deep Nets* (section 6.A), on internalise son gradient, la dérivée dx^{f*}/dx^c s’obtenant lors de l’évaluation de la loss function. Ce n’est pas de la triche, c’est de l’anticipation : le timing du jeu demeure respecté.

4 Ajouter la coalition

Mon *a priori* : « intégrer une coalition change tous les programmes, il y a trop d’interactions ». Mais il s’avère que c’est plus simple que je ne l’imaginais

(1) La structure des programmes ne change pas. Chaque extracteur maximise toujours son profit actualisé sous ses réserves. Intégrer la coalition = ajouter *quatre* choses, pas tout revoir :

1. un nouveau joueur (la coalition) dont l’action est de choisir des gisements à geler et les transferts ;
2. une modification des réserves (les gisements gelés sortent du stock $\Rightarrow$ offre $\downarrow$, prix $\uparrow$) ;
3. un sous-problème de marchandage de Nash pour le prix de gel T_j (**cf (2)**) ;
4. une re-résolution de l’équilibre $\Rightarrow$ nouveaux prix $\Rightarrow$ nouveaux payoffs $\Rightarrow$ élagage du DAG.

(2) La rente de réservation R_j est endogène On fixe T_j par marchandage de Nash (fonction Cobb-Douglas)¹ :

$$\max_{T_j} (A_j - T_j)^\gamma (T_j - R_j)^{1-\gamma} \implies T_j^* = (1 - \gamma) A_j + \gamma R_j,$$

Le point clé c’est que R_j est endogène : plus la coalition gèle, plus le prix monte, plus R_j (la rente d’extraction) monte, donc plus T_j^* monte. C’est une boucle « gel $\Rightarrow$ offre $\downarrow \Rightarrow$ prix $\uparrow \Rightarrow$ déviation plus profitable » qui me semblait ingérable, mais avec R_j endogénéisée, elle devient une **courbe d’offre de contrat croissante**, pas un chaos. C’est la fuite côté offre de Harstad, et c’est quantifiable.

De plus, cette fuite est atténuée : la coalition a intérêt à acheter les gisements **marginiaux** (peu chers, R_j faible, mais polluants). C’est possible parce que Coulomb, et nous avec la base actualisée, trouvons une corrélation coût–CarboneIntensity *faible* (0.04 – 0.07 ; on retrouve ≈ 0.02 avec la base actualisée) et il y a de fortes hétérogénéités intra-nationales sur la propreté/ le coût. Donc on peut geler du sale et pas cher *sans* amputer fortement le surplus des producteurs.

5 Premier modèle, et sa valeur ajoutée

Modèle 0 (sans coalition) : Nash-Cournot avec paramètre de collusion. Un cartel homogène doté d’un paramètre de collusion $\theta \in [0, 1]$, face à une frange agrégée price-taker. On résout un seul nœud du DAG : un équilibre de Nash-Cournot, d’abord sur 1-2 périodes, puis sur T périodes (pour faire apparaître l’effet de séquence). On obtient prix, profits, quantités d’équilibre (et leurs trajectoires en multi-période). Codé en Julia / Gurobi, sur un sous-ensemble d’assets (p.ex. 10 OPEP + 10 frange) issus des données de Léo.

Validation : reproduire De Cannière (*Pump it ?*). Même cadre Nash-Cournot, même $\theta \in [0, 1]$, données Rystad. Variables utilisées dans le papier (inputs) :

1. Cette forme satisfait les quatre axiomes du marchandage de Nash (John Nash, (https://fr.wikipedia.org/wiki/Jeu_de_marchandage_de_Nash#Solution_de_n%C3%A9gociation_Nash) si $\gamma = 0.5$. On peut aussi envisager des pouvoirs de négociation différents, dans ce cas $\gamma \neq 0.5$ et on ne respecte plus l’axiome de symétrie.

Paramètre	Valeur	Unité
Choke price α	225,5	\$/bbl
Pente demande inverse β	4,3	\$/bbl
Prix backstop b	102,5	\$/bbl
Coût marginal cartel k^c	18	\$/bbl
Coût marginal frange k^f	40 (bas) / 62,5 (haut)	\$/bbl
Stock initial cartel S_0^c	1212	milliards bbl
Stock initial frange S_0^f	619,5	milliards bbl
Taux d'intérêt r	0,028	—
Facteurs d'émission ω^c, ω^f	0,11083 ; 0,1525	tC/bbl
SCC	250	\$/tC

Ce qu'on vise à répliquer pour valider :

- *Cas limites* : $\theta = 0$ doit redonner l'issue parfaitement concurrentielle, $\theta = 1$ le monopole/cartel pur, sur le sous ensemble d'assets. Ces résultats sont vérifiables à la main
- *Comparatif dynamique* : Sur l'ensemble des assets, viser la réplcation des figures de De Cannière (figures 14 (a) et (b) trajectoires de prix et d'extraction) ou alors, puisque la base a légèrement changer, simplement comparer notre fit aux données réelles de la même manière.
- *Comparatif statique* : à θ croissant, prix initial *plus haut* et quantité initiale du cartel *plus basse*.
- Si on souhaite estimer le coefficient θ : le $\hat{\theta} \approx 0,17$ (s.e. 0,005 ; le cartel exerce $\approx 1/5$ de son pouvoir de marché potentiel. Voir estimation SMM et appendice D de De Cannière pour la boucle de convergence des prix.
- *Élasticité de la demande* : Fixée à $\approx -0,16$ (pente $\hat{\beta} \approx -69,66$). Charlotte De Cannière l'estime économétriquement en amont par variables instrumentales. Même si la base Rystad a changé, les paramètres de la demande restent les mêmes, on peut utiliser ces valeurs comme input sans reproduire l'économétrie.
- *Séquences d'équilibre* : selon les stocks initiaux, Nash-Cournot donne $S \rightarrow L \rightarrow R$ ou $S \rightarrow F \rightarrow R$: on doit retrouver les bonnes séquences à partir de nos stocks.

Rappel des régimes :

Régime S (Simultané) : $x_t^c > 0$ et $x_t^f > 0$.

Régime L (Leader seul) : $x_t^c > 0$ et $x_t^f = 0$.

Régime F (Frange seule) : $x_t^c = 0$ et $x_t^f > 0$.

Régime R (Ressource épuisée) : $x_t^c = 0$ et $x_t^f = 0$ (le prix atteint le niveau backstop b).

Une conclusion que lon peut rechercher : le cartel avance-t-il dans le temps l'extraction du pétrole cher *et* sale de la frange (effet de séquence) ? On décompose la perte de bien-être vs l'optimum social en effet de *conservation* et effet de *séquence*, sur nos données (il devrait y avoir peu à faire pour cela une fois que l'on a le solver de l'équilibre de marché)

Modèle 2 (avec coalition). On ajoute les contrats de gel (comme pensé par Harstad). **Premières conclusions visées** : réduction d'émissions par \$ de gel ; la courbe de conservation qui se *redresse* (escalade free-rider via R_j endogène) ; et un test direct de l'approche de Harstad « acheter les gisements marginaux » sur les vrais champs Rystad qui sont hétérogènes. Je constaterai à ce moment là si la résolution devient inopérante à cause de la dimension, et basculerai sur les pistes suivantes :

6 Pistes ML pour le closed-loop Stackelberg

Pourquoi du ML Naivement, le closed-loop souffre de la malédiction de la dimension : discrétiser les réserves de ~ 10 agents en 10 points = 10^{10} **états**, intenable. Si on suppose une frange agrégée et un cartel homogène, la structure oligopole-frange effondre le nombre d'état, mais on ne peut pas prendre en compte les hétérogénéités intra/inter nationales et l'impact des contrats sur les coûts de chaque membre de la frange. Le ML devient nécessaire car le nombre d'états demeure excessivement élevé si on souhaite modéliser quelque chose de concret et réaliste.

6.A "Deep" Equilibrium Nets

Comment le réseau pulvérise la dimension Au lieu d'une table de 10^{10} cases, on approxime la fonction valeur (ou la politique) par un réseau $V(S; \phi)$: l'état S est l'input, la valeur est l'output, et $\dim(\phi) \approx 10^3-10^4$ poids suffisent. On ne stocke jamais 10^{10} cases : on entraîne sur des états échantillonnés (quelques milliers à millions de points tirés), et le réseau *interpole* entre eux. Le coût est en nombre de paramètres et d'échantillons, et non pas avec points^{dim}.

Architecture (un réseau par agent stratégique) $\pi_C(S; \phi_C)$ pour le cartel, $\pi_F(S; \phi_F)$ pour la frange (et optionnellement un réseau-valeur par agent). Forward pass, couche par couche : $z^{(l)} = W^{(l)}a^{(l-1)} + b^{(l)}$, $a^{(l)} = \sigma(z^{(l)})$. Input normalisé $S = (S^c/S_0^c, S^f/S_0^f, t/T)$. 2-3 couches cachées $\times$ 64 neurones ? pourrait suffire (donc pas vraiment des "Deep" Nets)

Activations : ReLU (max(0,x)), et ce n'est pas un choix arbitraire ReLU est *linéaire par morceaux*, donc elle approxime bien des fonctions constantes/affines par morceaux : c'est la forme des politiques d'extraction, qui ont de **vrais sauts** (généralement on arrête d'extraire d'un coup, ou on se met à extraire). Un réseau lisse raterait ces kinks ; ReLU les encaisse. En sortie, une activation softplus mise à l'échelle par les réserves restantes impose la contrainte physique $0 \leq x^i \leq S^i$

Loss function

$$\mathcal{L}(\phi) = \mathbb{E}_{\mathcal{S}} \left[\left(\text{Résidu FOC}_{\text{frange}} \right)^2 + \left(\text{Résidu FOC}_{\text{cartel (avec réaction)}} \right)^2 \right]$$

on minimise simultanément les résidus des deux FOC, pour aboutir à un équilibre.

Entraînement : On tire un subset faible et aléatoire d'état (minibatch, pour la stochastic gradient descent ; cela revient à faire une intégration Monte Carlo de $\mathbb{E}_{\mathcal{S}}$), forward pass, calcul des résidus, backpropagation, gradient descent pour la mise à jour des poids ϕ ; on répète jusqu'à ce que les FOC tiennent $\approx$ partout. Post-entraînement, on obtient les trajectoires depuis S_0 avec une boucle déterministe : à chaque période t , les réseaux dictent les extractions $x_t^i = \pi_i(S_t)$, ce qui fixe le prix de marché $p_t = P(x_t^c + x_t^f)$, avant d'actualiser les stocks $S_{t+1}^i = S_t^i - x_t^i$ pour la période suivante.

Et le terme de réaction dx^f/dx^c s'obtient *gratuitement* (en coût computationnel) par différentiation automatique à travers le réseau de la frange. Il est dans la FOC du cartel.

6.B Reinforcement Learning sur multi-agents : une alternative écartée ?

Une approche alternative aux Deep Nets consisterait à modéliser le problème en apprentissage par renforcement (RL). Chaque agent (Cartel, Frange) est doté d'un réseau politique maximisant sa récompense cumulée empirique. Pour respecter la structure *Closed-Loop Stackelberg*, l'entraînement doit être imbriqué : la frange (follower) converge d'abord vers sa meilleure réponse, permettant au

cartel (leader) d'estimer empiriquement le gradient de politique par la règle de la chaîne (il intègre alors la politique de la frange dans son programme) :

$$\frac{\partial \Pi^c}{\partial x^c} + \frac{\partial \Pi^c}{\partial x^f} \cdot \frac{dx^f}{dx^c}$$

Problèmes que l'on peut anticiper : cette piste est structurellement inadaptée et risque de ne pas aboutir, pour plusieurs raisons :

1. *Métastabilité* : Le RL explorerait l'espace des politiques en échantillonnant des trajectoires temporelles, mais l'espace est hautement non convexe avec toutes les contraintes des agents hétérogènes, et le risque de rejoindre des équilibres non Nash ou instables est très élevée. J'ai déjà expérimenté ce genre de problème de convergence vers des états métastables en physique, le seul moyen de s'en prémunir est de moyennner sur un grand nombre de trajectoires pour écarter les aberrations, c'est très coûteux et jamais 100% fiable. Avec les Deep Nets, on échantillonne pas de trajectoire : on approxime la fonction politique.
2. *Très cher computationnellement* : L'entraînement imbriqué demande la convergence totale du follower à chaque étape d'exploration du leader, et l'explosion combinatoire à cause des hétérogénéités de Harstad reste un vrai problème, là où les réseaux (comme approximateurs universels) interpolent.
3. *Les "deep" nets ici sont physics-informed* : Là où le RL doit apprendre laborieusement les lois économiques/physiques (programmes des profits, contraintes de stocks) en explorant beaucoup de trajectoires, les Deep Nets restreignent l'espace de recherche directement aux équations de Bellman et aux FOC en minimisant les résidus de celles-ci, et ils sont pénalisés si ils en dévie.

7 Etapes immédiates

Coder le Modèle 0 (résolution exacte, 2 blocs) → le valider contre Benchekroun et/ou De Cannière → ajouter la coalition → le DAG et son élagage (incentive-compatibilité) → les Deep Nets quand là dimension sera un problème. Les Deep Nets me semblent les plus adaptés pour les raisons évoquées, et toujours les valider contre les précédents modèles (modèle 0, littérature) qui sont exacts sur les petits cas du début.

8 Analyse de données sur 15 pays producteurs




FIGURE 1 – Intensité carbone combinée par pays producteur (gCO₂e/MJ). Réplication actualisée de Coulomb et al., Fig. 1(b). gCO_2e/MJ pour la Figure 1, $kgCO_2e/bbl$ pour la suivante (comme chez Coulomb)




FIGURE 2 – Coût d'extraction privé vs Intensité carbone. Réplication actualisée de Coulomb et al., Fig. 2. La corrélation faible appuie l'approche de Harstad sur l'achat de gisements sales et pas chers par la coalition (ceux du coin supérieur droit)

TABLE 1 – Top 15 des parts de production mondiale (1992–2018) en % production globale

Pays	Données actualisées (%)	Coulomb et al. (%)
Saudi Arabia	12,7	14,0
Russia	12,2	12,0
United States	9,2	10,0
Iran	5,3	5,0
China	4,9	5,0
Venezuela	4,0	4,0
Mexico	3,9	4,0
UAE	3,7	4,0
Norway	3,3	3,0
Iraq	3,2	3,0
Kuwait	3,2	3,0
Nigeria	3,1	3,0
Canada	2,8	4,0
United Kingdom	2,3	2,0
Brazil	2,2	2,0

Méthode : $S_i = \frac{\sum_{t=1992}^{2018} q_{i,t}}{\sum_{t=1992}^{2018} Q_t}$.

Différence : Écart moyen = 7,9 %.

TABLE 2 – Comparaison *statique* des volumes récupérables (en Gb, 2019)

Pays	Resources (BAU)	Reserves 1P	Reserves 2P	Coulomb (Resources)
Saudi Arabia	245,0	56,0	90,0	286,0
Russia	141,0	49,0	76,0	143,0
United States	124,0	44,0	59,0	190,0
Iran	91,0	16,0	30,0	90,0
China	63,0	18,0	36,0	46,0
Mexico	19,0	5,0	10,0	25,0
UAE	76,0	18,0	32,0	72,0
Canada	69,0	25,0	41,0	101,0
Venezuela	13,0	3,0	5,0	34,0
Iraq	109,0	20,0	46,0	122,0
Norway	16,0	5,0	10,0	21,0
Kuwait	50,0	13,0	21,0	61,0
Nigeria	16,0	6,0	10,0	26,0
United Kingdom	8,0	2,0	4,0	13,0
Brazil	53,0	10,0	29,0	62,0

Total monde Resources : 1406,0 Gb (contre $\approx$ 1518 Gb pour Coulomb et al.).

TABLE 3 – Détail des réserves et capacités (en Gb), *modélisation dynamique (intégrale production future 2019-2100)*

Pays	1P	2P	Ressources Tech. [†]	Reserves BAU	Capacité [‡]
Saudi Arabia	55,5	89,7	289,9	225,0	9,3
United States	44,4	58,7	187,6	161,2	17,8
Russia	49,2	75,5	182,8	136,9	14,6
Iraq	19,9	46,1	119,2	105,5	6,0
Iran	16,5	30,0	113,0	84,1	6,2
UAE	18,3	31,7	93,5	72,8	3,1
Canada	24,5	41,3	141,1	67,0	4,2
China	18,4	35,9	69,1	59,1	5,0
Kuwait	12,7	20,8	57,1	50,4	2,6
Brazil	10,4	29,4	73,9	50,2	5,9
Kazakhstan	14,5	18,5	40,6	30,3	1,8
Qatar	8,6	15,2	46,7	27,7	1,4
Argentina	3,8	5,1	32,5	24,4	1,6
Mexico	4,9	10,0	40,0	19,0	4,5
Norway	5,4	10,2	23,2	16,5	4,2

Total monde Reserves BAU : 1376,38 Gb.

[†] La base n'exportant pas l'agrégat strict "3P", la variable *Technical recoverable resources* agit comme proxy de la borne supérieure absolue des volumes récupérables.

[‡] La capacité est modélisée comme la somme des pics de production historiques des gisements du pays.