

**Limites des réseaux de neurones pour
l'équilibre markovien sur le marché du
pétrole**

Résumé

L'enjeu du projet est d'évaluer la stabilité d'une coalition climatique qui chercherait à sécuriser son approvisionnement en pétrole face à un cartel pétrolier, qui lui chercherait à restreindre son offre pour artificiellement gonfler le prix. Cela suppose de résoudre un jeu dynamique d'extraction pour un grand nombre de structures de marché. Le concept d'équilibre pertinent *a priori* est markovien : chaque producteur réagit à l'état des stocks courant, révisant sa stratégie en fonction de la valeur du pétrole sous terre (prévision future), ou hors de terre (revenus immédiats). Cette idée de réaction aux stocks rivaux courants requiert une cartographie des actions et déviations possibles qui se heurte algorithmiquement au fléau de la dimension, et qui exclut toute tentative de résolution exacte. Nous tentons alors de mobiliser des réseaux de neurones informés par la physique, souvent mobilisés pour des problèmes complexes formulés par des EDP, et connus aussi pour leur capacité d'approximation universelle : l'obstacle ici sera la régularité des politiques d'extraction, et la qualité d'interpolation entre des points de stock. Les réseaux devront produire notamment une décision d'extraction à partir de données de stock à chaque période. Le but ultime sera de modéliser les structures du marché du pétrole sous forme d'un graphe acyclique et orienté : chaque nœud sera une configuration des blocs cartellistes, oligopolistes, coalition climatique, et frange concurrentielle, et il faudra posséder un solveur rigoureux permettant pour chacun de calculer les profits pour élaguer ensuite les déviations non profitables.

Contents

Introduction	2
1 Partie I - Cadre théorique	3
1.1 Programme d'extraction et structure de marché	3
1.2 Optimisation et équilibres	4
1.3 Dynamique intertemporelle et théorie des jeux	5
1.4 Le terme de feedback markovien	6
2 Partie II — Méthode algorithmique : les PINNs	7
2.1 Motivation des PINNs	8
2.2 Architecture informée par la physique	9
2.3 Échantillonnage et exploration du domaine	10
2.4 Dynamique d'entraînement	12
2.5 Validation et contrôles	13
2.6 Référence analytique et protocole de validation	14
3 Partie III — Résultats et diagnostics	15
3.1 Validation du réseau en boucle ouverte	15
3.2 L'échec d'identification de la Jacobienne	17
3.3 Mesurer le terme markovien sans réseau	18
3.4 Quand le terme markovien s'annule	19
3.5 Hétérogénéité et fragmentation	20
Discussion et conclusion	21
A Annexe A — Distributions	23
B Annexe B — L'oracle analytique en boucle ouverte	23
C Annexe C — Le test de déviation	24
Note sur l'usage d'IA	25

Introduction

L'évaluation de la stabilité d'une coalition climatique face à un cartel pétrolier demande de comparer les profits sous de multiples structures de marché (cartel, oligopoles, frange concurrentielle, partenaires de la coalition climatique). On ramène ce problème à la résolution d'un jeu dynamique d'extraction, à demande linéaire et coûts marginaux constants par agent. La forme du modèle est dictée par les données de champs Rystad exploitées par Jean [9] et Coulomb et al. [5], dont l'hétérogénéité de coûts et de capacités est ce qui donne son contenu au problème ; les calibrages employés dans ce rapport restent en revanche fictifs, l'objectif poursuivi ici étant algorithmique.

Le choix du concept d'équilibre est crucial pour ce travail. L'équilibre en boucle ouverte (engagement initial irrévocable sur une trajectoire) est calculable mais suppose que personne ne réagisse à l'état courant. L'équilibre markovien parfait (boucle fermée), où chaque acteur réajuste sa stratégie face à l'état courant des réserves concurrentes, lève cette limite. Cependant, la nécessité d'évaluer les déviations sur un espace continu à N dimensions fait face au fléau de la dimension, interdisant toute résolution analytique au-delà de trois agents. L'enjeu central de ce rapport est d'explorer une méthode de contournement : l'approximation des politiques d'extraction par des réseaux de neurones informés par la physique (PINNs), censés affranchir le solveur de la discrétisation spatiale par interpolation.

Cette piste algorithmique n'a pas abouti. Si le réseau converge avec haute précision vers l'équilibre en boucle ouverte (validé contre un oracle analytique développé spécifiquement), il échoue systématiquement à capter la dynamique markovienne. Le rapport démontre que cet échec est structurel et non paramétrique : le réseau s'avère incapable d'identifier les dérivées spatiales croisées $\partial x_k / \partial S_i$ qui portent pourtant tout le signal markovien. Le signal physique de cette interaction stratégique est d'un ordre écrasé par le bruit d'approximation inhérent aux besoins d'interpolation de nos réseaux de neurones. Le terme recherché évolue sous la résolution de l'instrument.

Pour statuer sur la nécessité économique de cet écart markovien, le terme est finalement mesuré sans réseau, par différences finies autour du sentier en boucle ouverte (approximation au premier ordre garantie par le théorème de l'enveloppe). Les résultats circonscrivent drastiquement la divergence entre les deux concepts : l'externalité stratégique est strictement nulle sous symétrie parfaite ou dès qu'un agent est à saturation de sa capacité physique. Elle ne naît que de l'hétérogénéité des coûts, se dilue avec la fragmentation du marché (le nombre de joueurs), et ne déplace la rente que de quelques pourcents au maximum. L'équivalence boucle ouverte / boucle fermée avec deux joueurs seulement ($N = 2$) de Benckroun et Withagen [3] semble pouvoir se généraliser asymptotiquement (avec N grand), ce sera l'objet de l'analyse de la partie III.

1 Partie I - Cadre théorique

1.1 Programme d'extraction et structure de marché

1.1.1 Position du problème

Considérons N producteurs, indexés par i , disposant chacun d'un stock privé $S_{i,0}$ de ressource épuisable. Le temps est discret, $t \in \{0, \dots, T\}$, et le facteur d'actualisation vaut $\delta = 1/(1+r)$. La demande inverse est linéaire, $p_t = \alpha - \beta \sum_k x_{kt}$, et les coûts marginaux c_i sont constants. Chaque producteur est en pratique borné par une capacité de production κ_i , pouvant être estimée sur les données de champs Rystad UCube exploitées par Jean [9] et Coulomb et al. [5] : on peut retenir le pic de production agrégée observé, $\kappa_i = \max_t \sum_{f \in i} q_{ft}$. Cette procédure d'estimation fixe la manière dont un calibrage empirique serait construit, mais les résultats présentés dans ce rapport reposent tous sur des paramètres fictifs, choisis pour calibrer un modèle plutôt que pour produire des résultats. L'objectif est ici algorithmique, et le passage aux données Rystad suppose un solveur validé. La suite (partie III) montrera que ce n'est pas encore acquis.

1.1.2 Une matrice pour toutes les conduites de marché

Avant d'écrire le programme d'optimisation, il faut définir comment chaque producteur perçoit son impact sur le marché. Ce qui distingue un oligopoliste d'un membre de cartel ou d'un *price-taker* est la quantité qu'il internalise lorsqu'il calcule son revenu marginal.

On encode cela dans une matrice de conduite $A \in \{0, 1\}^{N \times N}$ où $A_{ij} = 1$ si et seulement si i et j appartiennent au même bloc de coalition, la ligne d'un preneur de prix étant nulle. En posant $\Lambda_i = (Ax)_i$, un seul terme $\beta \Lambda_i$ sert à décrire le type d'agent et son impact sur le prix.

Type de producteur	Ligne de A	Λ_i	Marge stratégique perçue
Oligopoliste isolé	e_i^1	x_i	$p - \beta x_i - c_i$
Membre d'un cartel C	$\mathbf{1}_{\{C\}}$	$Q^C = \sum_{j \in C} x_j$	$p - \beta Q^C - c_i$
Franchise preneuse de prix	0	0	$p - c_i$

Cette représentation binaire est une simplification assumée : Okullo et Reynès [12] montrent que l'OPEP se comporte de façon nettement plus accommodante qu'un cartel parfaitement coordonné, tiraillée par de fortes incitations internes à dévier.

Le producteur i résout à extractions rivales données :

$$\max_{\{x_{it}\}_{t=0}^T} \sum_{t=0}^T \delta^t (p_t - c_i) x_{it} \quad \text{sous} \quad \sum_t x_{it} \leq S_{i,0}, \quad 0 \leq x_{it} \leq \kappa_i.$$

L'arbitrage intertemporel est régi par la fonction valeur, définie sur l'horizon résiduel :

$$V_i(S_t, t) = \max_{\{x_{i\tau}\}_{\tau=t}^T} \sum_{\tau=t}^T \delta^{\tau-t} (p_\tau - c_i) x_{i\tau},$$

et résolue localement par l'équation de Bellman :

$$V_i(S_t, t) = \max_{0 \leq x_{it} \leq \min(S_{it}, \kappa_i)} \left\{ (p_t - c_i) x_{it} + \delta V_i(S_t - x_t, t+1) \right\}.$$

¹Vecteur de base avec 1 en position i et zéros ailleurs.

1.2 Optimisation et équilibres

1.2.1 Multiplicateurs de Lagrange et interprétation

Écrivons le lagrangien en convention de minimisation, en notant μ_i le multiplicateur de la contrainte d'épuisement, γ_{it} celui de la capacité et ν_{it} celui de la non-négativité :

$$\mathcal{L}_i = \sum_t \delta^t [- (p_t - c_i)x_{it}] + \mu_i \left(\sum_t x_{it} - S_{i,0} \right) + \sum_t \delta^t [\gamma_{it}(x_{it} - \kappa_i) - \nu_{it}x_{it}].$$



Économiquement, μ_i est le prix implicite d'une unité de stock à la date initiale. La rente de rareté exprimée en valeur courante à la date t , c'est-à-dire le coût d'opportunité d'extraire une unité aujourd'hui, s'obtient en réactualisant ce scalaire : $\lambda_{it} = \mu_i(1 + r)^t$.

1.2.2 Unicité de la meilleure réponse individuelle par régime

Utilisons la stationnarité pour montrer que, en fixant les extractions des concurrents, la réaction optimale de l'agent i est unique. La condition de stationnarité $\partial \mathcal{L}_i / \partial x_{it} = 0$ donne la condition du premier ordre :

$$h_i(x_{it}) = p_t - \beta \Lambda_{it} - c_i - \lambda_{it} = \gamma_{it} - \nu_{it}.$$

En développant $p_t = \alpha - \beta \sum_j x_{jt}$ et $\Lambda_{it} = \sum_j A_{ij} x_{jt}$, on trouve que la fonction h_i est **strictement décroissante** en x_i , de pente $-\beta(1 + A_{ii})$: elle traverse zéro au plus une fois. Soit $\tilde{x}_{it}$ cette racine, telle que $h_i(\tilde{x}_{it}) = 0$, pouvant être virtuelle si elle ne respecte pas les contraintes, et soit x_{it}^* la décision optimale d'extraction. Trois configurations des multiplicateurs sont possibles, et chacune détermine la décision optimale effective de façon unique :

Régime intérieur ($\gamma_{it} = \nu_{it} = 0$). La condition de stationnarité se réduit à $h_i(x_{it}^*) = 0$. La stricte décroissance de h_i garantit que la racine est unique, donc $x_{it}^* = \tilde{x}_{it}$. La solution est intérieure, $0 < x_{it}^* < \kappa_i$, et la marge stratégique égale exactement la rente : $p_t - \beta \Lambda_{it} - c_i = \lambda_{it}$.

Régime de saturation ($\nu_{it} = 0, \gamma_{it} > 0$). La stationnarité impose $h_i(x_{it}^*) = \gamma_{it} > 0$. Puisque $h_i(\tilde{x}_{it}) = 0$ par définition, la stricte décroissance de h_i implique $x_{it}^* < \tilde{x}_{it}$. Examinons les candidats pour x_{it}^* : tout point strictement inférieur à κ_i forcerait $\gamma_{it} = 0$, ce qui contredit l'hypothèse. Le seul candidat physiquement possible est donc $x_{it}^* = \kappa_i$. On en déduit que $\kappa_i < \tilde{x}_{it}$: le producteur extrairait virtuellement davantage s'il n'était pas contraint.

Régime d'arrêt ($\nu_{it} > 0, \gamma_{it} = 0$). La stationnarité impose $h_i(x_{it}^*) = -\nu_{it} < 0$. Toujours par stricte décroissance, puisque $h_i(\tilde{x}_{it}) = 0$, on a $x_{it}^* > \tilde{x}_{it}$. Tout point strictement positif forcerait $\nu_{it} = 0$, une contradiction. La seule solution est $x_{it}^* = 0$, impliquant que $\tilde{x}_{it} < 0$. Même à production nulle, le revenu ne couvre pas le coût augmenté de la rente.

Les trois cas couvrent toutes les possibilités. La solution optimale s'écrit donc de façon compacte comme la *projection* de la racine libre sur l'intervalle admissible,

$$x_{it}^* = \min \left(\max (\tilde{x}_{it}, 0), \kappa_i \right), \quad \tilde{x}_{it} \text{ racine de } h_i$$

La résolution virtuellement intérieure suivie de la projection est permise par l'unicité de la meilleure réponse d'un agent, sachant les extractions concurrentes fixées, établie ci-dessus. Cet opérateur de projection sera utilisé dans l'architecture des réseaux de neurones, pour satisfaire à l'économie du problème.

1.2.3 Unicité de l'équilibre de Nash-Cournot

Avec $c_{it}^{\text{eff}} = c_i + \lambda_{it}$ et en développant le prix, la condition $h_i = 0$ du régime intérieur se réécrit $\alpha - \beta \sum_j (1 + A_{ij})x_{jt} = c_{it}^{\text{eff}}$, d'où l'expression explicite de la racine unique :

$$\tilde{x}_{it} = \frac{\alpha - c_{it}^{\text{eff}} - \beta \sum_{j \neq i} (1 + A_{ij})x_{jt}}{\beta(1 + A_{ii})}$$

Cette formule est la meilleure réponse d'un producteur aux quantités de ses concurrents, à rentes données, et sans contraintes physiques (avant projection). Le dénominateur $\beta(1 + A_{ii})$ est l'opposé de la pente de h_i : il vaut 2β pour un oligopoliste isolé, qui internalise son propre effet sur le prix, et β pour un preneur de prix, qui ne l'internalise pas. Ces conditions, pour chaque producteur, forment ensemble un système linéaire : en notant $\mathbf{1}$ le vecteur de 1,

$$\beta \underbrace{(\mathbf{1}\mathbf{1}^\top + A)}_B x_t = \alpha \mathbf{1} - c_t^{\text{eff}}.$$

La matrice B est symétrique, et sa forme quadratique est positive :

$$v^\top B v = \left(\sum_i v_i \right)^2 + \sum_{\text{blocs } K} \left(\sum_{i \in K} v_i \right)^2 \geq 0.$$

Elle est donc semi-définie positive. L'unicité de l'équilibre de Nash-Cournot exige la définie positivité, donc deux conditions :

- Il doit y avoir au plus un agent price-taker en régime intérieur. Sinon, deux lignes de la matrice B seraient identiques.
- Au plus un membre actif par cartel en régime intérieur, ou une agrégation préalable de chaque cartel en un macro-agent, sinon des lignes de la matrice B seraient là aussi identiques.

La solution n'est pas une simple inversion de matrice.

La tentation est d'écrire $x = B^{-1}(\alpha \mathbf{1} - c^{\text{eff}})/\beta$ et d'en rester là, mais il y a au moins un obstacle majeur : la matrice à inverser change selon les régimes, et n'intègre pas nativement les contraintes physiques. L'équation matricielle $Bx = Y$ présuppose en effet que tous les producteurs sont en régime intérieur. Or, dès qu'un agent sature sa capacité ($x_k = \kappa_k$) ou s'éteint ($x_k = 0$), sa condition d'optimalité quitte le système d'équations pour devenir une constante physique. Le système se réduit aux seuls producteurs libres (L), les quantités saturées (S) basculant au second membre :

$$\beta B_{LL} x_L = Y_L - \beta B_{LS} x_S$$

L'inversion exigerait de connaître la matrice amputée B_{LL} , donc de deviner *a priori* quels producteurs vivent aux coins, ce qui exigerait de tester 3^N configurations par période. L'algorithme par itération de meilleures réponses, décrit en annexe B, contourne ce mur combinatoire.

1.3 Dynamique intertemporelle et théorie des jeux

1.3.1 La règle de Hotelling et son domaine de validité

Toute la complexité de la dimension intertemporelle se cache dans la fonction rente λ . De la définition établie plus haut $\lambda_{it} = \mu_i(1 + r)^t$ découle immédiatement la loi d'évolution au taux d'intérêt de la rente, dite règle de Hotelling [8] :

$$\lambda_{it} = \delta \lambda_{i,t+1}.$$

Cette loi ne suppose rien sur le régime spatial dans lequel se trouve le producteur (intérieur, contraint ou éteint) car elle dérive uniquement du scalaire μ_i . Mais elle suppose une hypothèse stratégique forte : la constance de ce multiplicateur tout au long de l'horizon, ce qui définit la boucle ouverte.

1.3.2 Deux cadres de théorie des jeux : boucle ouverte et boucle fermée

Ce projet se place dans un jeu de Nash-Cournot [14], où les extractions sont simultanées à chaque période, à l'inverse du jeu de Stackelberg. Chacun des deux peut se jouer en boucle ouverte ou fermée.

En boucle ouverte, le circuit d'information est rompu. Une stratégie est un vecteur $\mathbf{x}_k = (x_k(0), \dots, x_k(T))$, calculé et figé de manière irrévocable à la date initiale. Le producteur s'engage sur une trajectoire déterministe sans jamais réévaluer sa position face à l'évolution réelle des stocks. L'objection habituelle à ce cadre est la non-crédibilité de l'engagement, mais elle vise en réalité l'équilibre de von Stackelberg en boucle ouverte, où le meneur promet une restriction future dont il voudra dévier une fois la frange engagée [4]. En Nash-Cournot, la difficulté est plus faible : tant que les rivaux s'en tiennent à leur plan, le plan initial reste une solution du problème tronqué depuis l'état atteint, et l'équilibre est donc faiblement cohérent temporellement. Ce que ce cadre ignore, en revanche, c'est qu'un rival puisse réagir à l'état courant.

En boucle fermée, l'information forme une boucle de rétroaction continue. Une stratégie devient une politique d'extraction $\sigma_k(S, t)$, dépendante de l'état courant du système. Le producteur i internalise le fait qu'une variation de son stock sera observée par ses rivaux et provoquera la ré-optimisation de leurs trajectoires futures. Cette anticipation engendre une externalité stratégique qui vient ajouter un terme de réaction à la règle d'Hotelling (fb pour *feedback*) :

$$\lambda_{it} = \delta \lambda_{i,t+1} + \text{fb}_{it}.$$

L'équilibre associé est qualifié de Sub-Game Markov Perfect Equilibrium (MPE). Le cadre markovien est une sous-classe de la boucle fermée où la règle de décision, sachant l'état courant, ne dépend plus de l'historique passé. Un équilibre MPE exige que ces politiques forment un équilibre de Nash depuis n'importe quel état des stocks possibles (tout sous-jeu). Sur un espace d'états continu, cela équivaut à résoudre un arbre de décision aux ramifications infinies à chaque nœud temporel. C'est là que naît le fléau de la dimension.

1.4 Le terme de feedback markovien

1.4.1 Origine et dérivation

Le programme du producteur i en boucle fermée s'écrit

$$V_i(S) = \pi_i(x(S)) + \delta V_i(S - x(S)),$$

où $x(S)$ est le profil markovien complet, c'est-à-dire un vecteur de *fonctions* de l'état : c'est ce qui engendre tout l'écart avec la boucle ouverte.

La rente de i étant par définition la valeur marginale de son propre gisement, $\lambda_i = dV_i/dS_i$, on différencie cette équation par rapport à S_i . Le stock agit par deux canaux : il entre directement dans l'argument de continuation, et indirectement en modifiant l'ensemble des décisions $x_k(S)$ prises aujourd'hui. En notant V'_i la valeur à l'état successeur, la règle de la chaîne donne

$$\lambda_i = \underbrace{\delta \lambda'_i}_{\text{continuation}} + \sum_k \underbrace{\left[\frac{\partial \pi_i}{\partial x_k} - \delta \frac{\partial V'_i}{\partial S_k} \right]}_{\text{valeur marginale d'une unité extraite par } k} \cdot \frac{\partial x_k}{\partial S_i}.$$

Le crochet mesure le coût net, pour i , d'une extraction supplémentaire par le rival k : elle déprime le prix aujourd'hui, mais épuise le gisement concurrent, ce qui assainit le marché de demain. Il fait intervenir les dérivées croisées de la valeur, seuls objets de la dérivation qui échappent à l'indice propre.

Le terme diagonal se calcule explicitement. Comme $\partial\pi_i/\partial x_i = p - c_i - \beta x_i$ et que la condition du premier ordre donne $\delta\lambda'_i = p - \beta\Lambda_i - c_i$, il vaut $\beta(\Lambda_i - x_i)$: nul pour un oligopoliste isolé, qui internalise exactement sa propre quantité — c'est le théorème de l'enveloppe, une variation marginale d'un choix déjà optimal n'ayant pas d'effet de premier ordre — mais non nul pour un membre de cartel ($\beta(Q^C - x_i)$) ou un preneur de prix ($-\beta x_f$), qui n'optimisent pas contre leur véritable impact.

Le terme proprement markovien est donc la somme hors-diagonale,

$$\text{fb}_i = \sum_{k \neq i} \left[\frac{\partial\pi_i}{\partial x_k} - \delta \frac{\partial V'_i}{\partial S_k} \right] \cdot \frac{\partial x_k}{\partial S_i} \quad \text{et} \quad \lambda_i = \delta\lambda'_i + \text{fb}_i.$$

1.4.2 Insertion dans le système et sens économique

De façon contre-intuitive, fb_i n'apparaît pas dans la condition du premier ordre courante, qui reste $h_i = p - \beta\Lambda_i - c_i - \delta\lambda'_i$. Il s'injecte dans la relation d'enveloppe, et n'atteint donc la décision qu'à la date *précédente*, par le biais de l'anticipation $\delta\lambda'_i$.

Son effet est cumulatif plutôt que local : en itérant la relation d'enveloppe vers l'arrière,

$$\lambda_i(0) = \sum_t \delta^t \text{fb}_i(t) + \delta^T \lambda_i(T), \quad (1)$$

de sorte que la rente initiale accumule l'ensemble des feedbacks futurs : une seule date où le terme est non nul déplace la rente de toutes les dates qui la précèdent. C'est pourquoi un terme instantané très faible peut produire un écart d'équilibre mesurable, propriété que la partie III exploite.

Économiquement, ce terme est une *externalité stratégique internalisée*. En boucle ouverte, le producteur ignore que la conservation de son stock modulera les extractions futures de ses rivaux ; en boucle fermée, il valorise cette force de dissuasion.

1.4.3 Signe et croisement des sentiers

Le signe de fb_i n'est pas déterminé a priori : le crochet oppose la baisse de prix à la valorisation de l'épuisement rival, et $\partial x_k/\partial S_i$ est négatif, sauf lorsqu'un preneur de prix intérieur épingle le prix à $c_f + \lambda_f$ et absorbe la baisse. Le signe dépend donc de la configuration des régimes.

Lorsque le produit est positif, $\lambda^{\text{CL}} > \lambda^{\text{OL}}$ et le producteur devient plus conservateur. En unités déflatées $\ell_t = \delta^t \lambda_t$, la règle de Hotelling impose un profil plat quand la relation augmentée donne $\ell_{t+1} = \ell_t - \delta^t \text{fb}_t$, décroissant. Les deux sentiers extrayant le même stock, le profil décroissant doit partir au-dessus et finir en dessous, faute de quoi il sur-extrait partout : d'où un croisement unique, le producteur markovien extrayant moins tôt et davantage tard. Cette conclusion ne vaut plus si le signe de fb change au cours de l'horizon.

2 Partie II — Méthode algorithmique : les PINNs

La partie précédente a établi la pertinence de l'équilibre markovien, mais sa résolution exacte se heurte à un coût rédhibitoire en $\mathcal{O}(k^N)$: pour étudier des déviations sur un support continu de stocks, il faut discrétiser en une grille avec un pas k , et ce pour chacun des N agents. Cette

partie décrit la tentative de contournement par l'utilisation de réseaux de neurones : comment la justifier théoriquement, comment l'architecture satisfait à la théorie, comment les réseaux sont entraînés et validés, et où la solution open-loop peut servir d'instrument de contrôle.

2.1 Motivation des PINNs

L'idée d'entraîner un réseau en pénalisant l'écart aux équations du modèle plutôt qu'en l'ajustant à des données remonte aux réseaux informés par la physique de Raissi et al. [13], et a été transposée aux modèles économiques dynamiques par les *deep equilibrium nets* d'Azinovic et al. [1], dont l'architecture retenue ici s'inspire directement.

2.1.1 Approximation universelle et borne de Barron

Un réseau de neurones² construit une fonction hyper-paramétrée pour en approximer une autre qui n'est pas calculable. Pour un réseau à une couche, la fonction qui approxime prend la forme

$$f_n(u) = \sum_{m=1}^n a_m \sigma(w_m^\top u + b_m),$$

où σ est une fonction non-linéaire non-polynomiale et où les (a_m, w_m, b_m) sont les paramètres ajustés pendant l'entraînement. Les théorèmes d'approximation universelle nous apprennent que cette famille $(f_n)_n$ est dense dans l'espace des fonctions continues sur un compact : pour toute cible et toute tolérance, il existe un n suffisant. Ce résultat repose cependant sur la régularité de la fonction cible, et il ne dit rien du nombre de neurones nécessaire.

La borne de Barron [2] apporte cette information manquante : si la cible f admet une transformée de Fourier $\hat{f}$ dont le premier moment

$$C_f = \int \|\omega\| |\hat{f}(\omega)| d\omega$$

est fini, alors l'erreur quadratique d'approximation par un réseau à n neurones est majorée par une quantité de l'ordre de $\frac{C_f}{\sqrt{n}}$.

Le point remarquable est que cette borne ne comporte aucune dépendance explicite en la dimension d de l'espace d'entrée : elle relie le nombre de neurones à la régularité de la cible, mesurée par C_f , et non au volume à couvrir. C_f dépend néanmoins de la cible et peut donc croître avec d . Une approximation par grille exige, elle, $\mathcal{O}(\varepsilon^{-d})$ points pour une précision ε : c'est précisément le **fléau de la dimension**. C'est ce qui rend l'approche neuronale si attrayante pour un jeu à N producteurs.

Il faut noter aussi que ce résultat porte sur la *largeur* du réseau, et qu'il tient pour une seule couche. Il ne dit donc rien non plus de l'effet d'empiler des couches. En somme, la performance de notre réseau sera modulable mais dépendra fortement de notre proximité avec les hypothèses du théorème, donc de la régularité de la cible.

La question centrale est donc : la politique d'équilibre de notre modèle possède-t-elle un C_f fini ?

2.1.2 Ruptures de dérivée et divergence de la constante

La partie I a établi que les conditions de Karush–Kuhn–Tucker découpent l'horizon en trois régimes (intérieur, saturé, éteint) et que la politique d'équilibre passe de l'un à l'autre à des dates déterminées par les conditions physiques et économiques. En ces points, la politique est

²Excellente vidéo qui vaut un cours entier sur les réseaux de neurones : <https://www.youtube.com/watch?v=aircAruvnKk>

continue mais sa dérivée ne l'est pas : $\partial x_i / \partial S_i$ vaut 0 du côté saturé et une valeur non nulle du côté intérieur. La politique d'équilibre présente donc des ruptures de pente (des « kinks »), aussi bien en temps qu'en espace des stocks, sur les frontières séparant les régimes.

Cette non-régularité a une conséquence directe sur la borne de Barron C_f . Pour une fonction continue dont la dérivée première saute, la dérivée seconde comporte une masse de Dirac sur la frontière, de sorte que $|\hat{f}(\omega)|$ décroît comme $\|\omega\|^{-2}$ aux hautes fréquences (démonstration en annexe A). Le premier moment se comporte alors comme

$$C_f \sim \int^\infty \|\omega\| \cdot \|\omega\|^{-2} d\omega = \int^\infty \frac{d\omega}{\|\omega\|},$$


qui diverge, mais logarithmiquement. La constante qui contrôle la borne n'est donc pas finie pour une politique comportant des bascules de régime, et la borne d'approximation en $C_f/\sqrt{n}$ s'effondre.

Pour nuancer, cette divergence pénalise surtout l'approximation d'une fonction anguleuse (les kinks) par un réseau intrinsèquement lisse (l'activation SiLU $\sigma(z) = z \cdot \text{sigmoïde}(z)$ retenue ici étant $\mathcal{C}^\infty$). La sous-partie suivante montre comment l'architecture contourne cette difficulté pour la politique elle-même : l'opérateur de projection introduit en Partie I permet de gérer la rupture du coin supérieur (régime de saturation sur κ), que le réseau n'a donc pas à essayer d'approximer. Mais cela ne résout pas tout, et nous explorerons en Partie III les pistes d'explications pour l'échec d'identification de l'équilibre markovien.

2.2 Architecture informée par la physique

Le solveur associe à chaque producteur un réseau à tronc partagé et trois têtes, l'une pour la politique, l'une pour la valeur, l'une pour le co-état (la rente). Le tronc retenu compte trois couches cachées de 128 neurones. Pour rappel, la borne de Barron ne concerne que la largeur, et prédit une amélioration en $1/\sqrt{n}$ sous condition de régularité de la cible. Notre cible n'étant pas régulière, cette garantie ne s'applique pas, et l'expérience le confirme : augmenter la largeur n'a pas apporté de gain, alors que le passage de deux à trois couches a nettement amélioré la précision. La profondeur semble mieux réagir que la largeur aux non-régularités.

Chaque réseau reçoit en entrée l'état complet S pour produire ses têtes, ce qui est la définition même du caractère markovien et rend calculables les dérivées croisées. Le temps aussi est en entrée, de façon discrète puisque l'horizon est fini et les dates dénombrables.



projections physiques : régime de saturation, positivité et condition terminale sont imposés ici, jamais appris

Projection topologique des régimes. Une seule ligne satisfait les contraintes de capacité et de positivité de la partie I :

```
| x = torch.minimum(torch.minimum(S, KAP), F.softplus(z))
```

C'est l'**opérateur de projection**. Il garantit par construction $x \leq \kappa$ et peut l'atteindre exactement (grâce à la fonction min), $x \leq S$, et $x \geq 0$ (positivité de $\text{softplus}(z) = \log(1 + e^z)$). Toutefois, la fonction softplus étant strictement positive, l'annulation stricte $x = 0$ exige que le

réseau pousse sa variable latente vers $z \rightarrow -\infty$. Sur notre calibration, nous utilisons un seuil arbitraire correspondant environ à $z \simeq -9,2$, en deçà duquel on force $x = 0$. Ce coin inférieur constitue alors une difficulté sérieuse, rendant la projection imparfaite par rapport à la coupure nette offerte par le $\min$ sur la borne supérieure. Néanmoins, les multiplicateurs de Lagrange γ et ν ne sont jamais estimés, les régimes qu'ils encodent sont réalisés géométriquement.

Puisque $0 \leq x \leq S$, l'équation d'état $S' = S - x$ donne $0 \leq S' \leq S$: le domaine accessible se contracte à chaque pas, et la suite des boîtes $[0, S]$ est emboîtée et décroissante. Le réseau connaît ainsi le sens du système avant même d'avoir commencé à optimiser. La flèche du temps physique et l'épuisement géologique ne sont pas des propriétés à découvrir dans les données, mais des contraintes structurelles qui interdisent d'emblée toute trajectoire aberrante : un stock qui remonterait, une extraction qui excéderait les réserves.

Formes temporelles de la valeur et du co-état. Les deux autres têtes reçoivent un traitement analogue. Elles s'écrivent

$$V = \mathbb{K}\{t < T\} \text{softplus}(w) V_{\text{ref}} G(t), \quad \lambda = \mathbb{K}\{t < T\} \text{softplus}(l) \alpha G(t).$$

Le softplus impose la positivité, ce qui est ici une propriété économique et non une commodité : un gisement ne peut pas avoir une valeur négative, et la rente de rareté est un multiplicateur positif et représente un coût d'opportunité. Les facteurs V_{ref} et α fixent l'ordre de grandeur (α est le choke price, prix au-delà duquel la demande est nulle).

Le facteur $G(t) = (1 + r)^{t - (T-1)}$ répond d'abord à un impératif de normalisation : le décalage $t - (T - 1)$ garantit que ce facteur vaut exactement 1 à la dernière date de décision $T - 1$, ce qui prévient toute explosion numérique sur les horizons longs et ancre l'ordre de grandeur terminal autour des constantes α et V_{ref} . Il assure ensuite la « déflation » de l'apprentissage : en boucle ouverte, la règle de Hotelling est géométrique au taux $1 + r$. G vient ainsi ramener la variable latente que le réseau doit apprendre à une constante. En boucle fermée, la loi comporte un terme de feedback mais G permet d'aplatir la dynamique, déchargeant ainsi le réseau de la tendance dominante, lui permettant d'allouer sa capacité d'ajustement à l'apprentissage de l'écart markovien.

Le facteur $\mathbb{K}\{t < T\}$ annule V et λ à l'horizon, à la précision machine, ce qui fournit un **ancrage terminal exact** à la chaîne de récurrence arrière. À la date finale, le gisement est alors soit vidé, soit économiquement irrécupérable, et le réseau n'a pas besoin de l'apprendre.

Tous ces éléments ne sont pas propres à l'équilibre markovien. Ils se transposent tels quels à un solveur en boucle ouverte, où il suffit de désactiver le terme de feedback dans la cible du co-état : nous avons vu en Partie I que seul le co-état λ portait les termes de réaction croisés.


2.3 Échantillonnage et exploration du domaine

L'entraînement doit choisir où évaluer les résidus dans l'espace des stocks. Le domaine physique est l'hyper-rectangle (la boîte) $[0, S_0^1] \times \dots \times [0, S_0^N]$, que l'équation d'état ne fait que rétrécir au fil du temps ; l'échantillonnage déborde légèrement au-delà, jusqu'à $1,25 S_0$, afin d'avoir des points autour de la borne haute pour les calculs de dérivées (autrement, on aurait dû extrapoler, ce qu'un réseau fait très mal).

L'échantillonnage utilise un *rollout*. On appelle *rollout* la simulation séquentielle d'une trajectoire complète sous la politique courante : partant d'un état initial, on appelle le réseau et ses paramètres courants pour obtenir $x(0)$, on en déduit $S(1) = S(0) - x(0)$, et l'on répète jusqu'à l'horizon. Lorsque le rollout est utilisé pendant l'entraînement, la trajectoire déroulée se précise à mesure que l'entraînement avance, puisque les paramètres sont ajustés au fil des

itérations. Il sert dans ce projet à trois usages distincts : délimiter la région que la politique visite effectivement *pendant* l'entraînement, construire une cible pour le niveau de la fonction valeur en accumulant à rebours le profit actualisé le long de la trajectoire, et, en partie III, évaluer des continuations après déviation.

À chaque itération, l'optimiseur ne traite pas un point isolé mais un lot (batch) de B états indépendants : le réseau d'un joueur reçoit en entrée un tenseur de B couples (S, t) . Les points $b \in B$ sont tirés de trois lois différentes illustrées sur la figure ci-dessous. $S \in \mathbb{R}^N$ est une variable spatiale continue (préalablement normalisée par les réserves initiales S_0), et la date $t \in \{0, \dots, T\}$ bénéficie d'un plongement vectoriel (*embedding*) discret. L'*embedding* associe à chaque date un vecteur de paramètres indépendant, concaténé à l'état physique. Cet *embedding* vise à rendre le réseau aveugle à toute chronologie, et à transférer l'intégralité du couplage intertemporel à la fonction de perte (qui contient, nous le verrons, les résidus des équations de Bellman et de Hotelling notamment). C'est la minimisation de ces résidus économiques qui connecte les dates entre elles, l'entrée ne donne aucune information au réseau sur la proximité temporelle entre les dates t et $t + 1$.



Le tube est constitué de rollouts partant d'états initiaux tirés autour de S_0 , et rafraîchis périodiquement (un buffer), car le rollout se précise à mesure que les paramètres du réseau sont ajustés. Il définit la région que la politique visite effectivement, et fournit accessoirement la cible mesurée pour le niveau de la fonction valeur.

Le bruit gaussien transverse n'a pas pour objet de couvrir tout l'espace mais de fournir de la variation dans le voisinage proche du sentier. Sans lui, les dérivées $\partial V / \partial S$ et $\partial x / \partial S$ n'existeraient pas, puisque tous les points d'évaluation seraient alignés sur une courbe de dimension un. Un échantillonneur à bruit nul a d'ailleurs produit une fonction de perte minuscule (10^{-6}) pour une trajectoire largement fautive : c'est un argument de plus à la nécessité de valider le réseau autrement que par la simple lecture de la magnitude de la perte. L'écart-type retenu, $\sigma_j = 0,05 S_{0j}$, est l'échelle à laquelle la partie III comparera le signal recherché au bruit d'approximation.

Le tirage uniforme ne couvre pas l'hyper-rectangle et n'en a pas l'ambition, son volume croissant exponentiellement en N . Sa fonction est d'empêcher le réseau de devenir arbitraire loin du tube, ce qui importe parce que le déroulement peut dériver, et les déviations aussi.

2.3.1 Calcul markovien et verrouillage stratégique

L'évaluation sur un lot de taille B vectorise les sorties $x, V, \lambda \in \mathbb{R}^{B \times N}$. Les dérivées spatiales croisées forment des tenseurs d'ordre trois ($\mathbb{R}^{B \times N \times N}$) : la Jacobienne des politiques $J[b, k, j] =$

$\partial x_k / \partial S_j^{(b)}$ et le crochet de valeur marginale mesurant l'externalité, $\Gamma[b, i, k] = \frac{\partial \pi_i^{(b)}}{\partial x_k} - \delta \frac{\partial V_i^{(b)}}{\partial S_k}$.

Le calcul du feedback markovien écarte le terme $k = i$ (relevant de la condition du premier ordre, pas du feedback) via le produit de Hadamard. On encode alors le terme de feedback sous cette forme :

$$M[b, i, j] = \sum_k (\Gamma \odot (\mathbf{1}\mathbf{1}^\top - I))[b, i, k] J[b, k, j]$$

Le feedback du producteur i est la diagonale de ce résultat : $\text{fb}_i = M[b, i, i]$. Cette multiplication matricielle a un coût en $\mathcal{O}(B N^3)$, le terme markovien est alors trivial à calculer ; la difficulté réside dans la force de son signal.

2.4 Dynamique d'entraînement

L'évaluation de l'architecture décrite jusqu'à maintenant repose sur un entraînement semi-supervisé (« Physics-Informed ») : l'optimisation des paramètres passe par la minimisation de l'écart aux équations physiques et économiques, tout écart étant pénalisé par la fonction de perte $\mathcal{L}$.

Une itération type. Un réseau correspond à un joueur. Les N réseaux ne sont couplés que par le prix de marché $p = \alpha - \beta \sum_k x_k$, ce qui permet aux N réseaux de produire un équilibre de Nash décentralisé. Les autres cibles (λ , V , et x) sont détachées du graphe de calcul par la fonction `torch.detach()` pour empêcher un réseau de modifier artificiellement ses croyances futures pour réduire sa perte locale. Un lot d'états (S, t) est tiré selon la stratégie d'échantillonnage décrite ci-dessus. Un premier *forward pass* évalue les réseaux en ces points, un second aux états successeurs $(S - x, t + 1)$, ce qui produit les extractions, les valeurs et les co-états. On forme alors les résidus, c'est-à-dire les écarts à zéro des conditions d'optimalité : condition du premier ordre, relation de Hotelling, et équation de Bellman. La perte globale est la somme pondérée de leurs carrés,

$$\mathcal{L}(\theta) = \sum_q w_q \|R_q(\theta)\|^2,$$

où θ désigne l'ensemble des paramètres. La *backward propagation* calcule ensuite le gradient $\nabla_\theta \mathcal{L}$ par différentiation automatique, en remontant le graphe de calcul de la perte vers les paramètres par applications successives de la règle de chaîne, et les paramètres sont mis à jour par l'optimiseur Adam [10].

Une conséquence de ce schéma est que l'optimiseur ne traite pas les résidus séparément, il descend le gradient de leur somme. Un terme dont le gradient est petit devant celui des autres est de fait injustement ignoré, ce qui impose de pondérer la somme.

Brève digression. Cela amène *a posteriori* à réfléchir sur la pertinence de l'approche dans un contexte si complexe physiquement et économiquement, puisque le gradient peut peiner à trouver la direction optimale pour réagir à un tel environnement ; cette direction pouvant ne même pas exister. La littérature sur les PINNs documente précisément ce type de défaillance, imputable au mauvais conditionnement du paysage de perte et au déséquilibre des gradients plutôt qu'à un manque d'expressivité du réseau [11, 15].

Pourquoi un arbitrage local devrait suffire pour l'horizon total. Le réseau ne prédit jamais une trajectoire complète. Il ne traite que des paires d'instantanés consécutifs $(t, t + 1)$, et résout à chaque fois un arbitrage local : extraire aujourd'hui ou conserver pour demain. Le fait que la résolution de tous ces arbitrages locaux reconstitue la solution intertemporelle n'a rien d'automatique et repose sur quatre propriétés de l'architecture.

La première est l'optimalité de Bellman sur le pas court : les conditions du premier ordre et l'équation de Bellman écrites entre t et $t + 1$ caractérisent l'optimum, à condition que la valeur de continuation soit correcte. La deuxième est l'ancrage terminal, qui fournit cette valeur de continuation au bout de la chaîne : en T , le stock restant ne vaut plus rien, soit parce qu'il a été épuisé, soit parce qu'il n'est plus économiquement exploitable. C'est une propriété immuable depuis laquelle l'information remonte le temps. La troisième est la contrainte géologique : l'état ne peut pas quitter la boîte $[0, \text{Stocks}_0]$, et cette boîte se contracte nécessairement à chaque pas. La quatrième est l'indépendance structurelle garantie par l'embedding temporel : le réseau n'interpolant pas continûment entre t et $t + 1$, l'entière responsabilité du couplage dynamique repose formellement sur la minimisation de ces résidus locaux.

Ces quatre propriétés sont nécessaires, mais pas encore suffisantes : il faut encore que l'échantillonnage couvre correctement la région de l'espace d'états où la trajectoire vit, ce qui justifie la stratégie décrite plus haut.

2.5 Validation et contrôles

2.5.1 Les résidus et leur statut

Dans un réseau informé par la physique (PINN), la fonction de perte constitue l'intégralité de l'environnement auquel le réseau a accès. C'est le seul signal transmis au réseau pour apprendre. La minimisation de ces résidus est le mécanisme par lequel les équations du système contraignent les poids neuronaux jusqu'à faire émerger la rationalité économique.

Équation du résidu	Objet supervisé	Poids	Nature de la cible
$R_{\text{foc}} = x - \text{proj}_{[0, \kappa]}(x + h/\text{DEN})$	politique x	1	Meilleure réponse projetée
$R_{\text{env}} = \lambda - \text{tgt}$	tête λ	1	Détaillé en section suivante
$R_{\text{bell}} = V - (\pi + \delta V')$	tête V	1	Anticipation locale à un pas
$R_{\text{vmc}} = V - V^{\text{rollout}}$	niveau de V	1	Cumul total simulé empiriquement
$R_{\text{lam}} = \partial V_i / \partial S_i - \lambda_i$	$\partial V_i / \partial S_i$	0,01	Cohérence théorique
$R_{\text{reg}} = \partial V_i / \partial S_j - \nabla V^{\text{rollout}}$	$\partial V_i / \partial S_j$	0,1	Gradient empirique (mesuré sur rollout)

Parmi ces termes, nous détaillerons ici le fonctionnement de R_{foc} . Les autres résidus visent principalement à calibrer les têtes d'évaluation (la valeur et la rente). La rente, qui porte la complexité de l'arbitrage intertemporel, sera discutée au paragraphe suivant. Le résidu R_{foc} , en revanche, concentre à lui seul la complexité spatiale du jeu : il encode la mécanique des bascules de régime.

En notant le rendement statique $\text{marg}_i = p - \beta \Lambda_i - c_i$ et l'opportunité d'arbitrage $h = \text{marg}_i - \delta \lambda'_i$ (où λ' désigne la rente à la période suivante $t+1$), les différents régimes et la condition du premier ordre se condensent en une seule ligne PyTorch :

```
| R_foc = x - torch.clamp(x + h/SLP, torch.zeros_like(x), cap)
```

L'opérateur `clamp(z, a, b)` projette la variable z sur l'intervalle $[a, b]$, valant z à l'intérieur de ce segment, et butant sur a ou b aux extrémités. Cette formulation compacte pilote l'apprentissage par une disjonction de cas continue, réconciliant les trois états possibles :

Le régime intérieur ($h = 0$). Le rendement immédiat équivaut parfaitement au coût d'opportunité géologique. Pour une prédiction x strictement intérieure ($0 < x < \kappa$), le terme d'incrément h/SLP , où $\text{SLP} = \beta(1 + A_{ii})$ est l'opposé de la pente de h_i établie en §1.2.2, est nul. L'opérateur `clamp` renvoie x , et le résidu $x - x = 0$ est idéalement minimisé. Si le réseau déviait en proposant un $x \rightarrow 0$, la restriction de l'offre ferait mécaniquement grimper le prix p

et chuter l'impact marginal βx . Le terme h deviendrait alors positif, forçant la tête neuronale à corriger son extraction à la hausse plutôt que de s'éteindre.

Le régime saturé ($h > 0$). L'extraction est très profitable ; l'agent a intérêt à saturer son infrastructure. Raisonnons par l'absurde : si le réseau propose une valeur $x < \kappa$, l'incrément $\varepsilon = h/\text{SLP}$ est strictement positif. Le `clamp` autorise ce mouvement, et le résidu s'évalue à $x - (x + \varepsilon) = -\varepsilon \neq 0$. La descente de gradient va donc pousser x à la hausse itération après itération. L'erreur ne s'annule que lorsque x atteint la capacité κ : l'argument interne devient $\kappa + \varepsilon$, la fonction le tronque à κ , et le résidu vaut enfin $\kappa - \kappa = 0$.

Le régime éteint ($h < 0$). Symétriquement, le baril vaut plus sous terre qu'à la vente. Si le réseau sort un $x > 0$, l'incrément ε est négatif, générant une erreur $-\varepsilon \neq 0$. L'optimiseur contractera x jusqu'à toucher 0, seuil où la troncature inférieure annule exactement le résidu.

En définitive, ce bloc annule la perte si et seulement si x correspond à la meilleure réponse contrainte exacte, absorbant nativement la logique des multiplicateurs de Lagrange documentée en partie I. C'est l'essence même de l'apprentissage informé par la physique : laisser la structure géologique piloter les poids du réseau, sans données cibles externes, jusqu'à ce que la rationalité économique soit atteinte.

2.5.2 La cible du co-état et l'ancrage physique

L'apprentissage du co-état (la tête λ) capte la dimension intertemporelle et stratégique du jeu. Le résidu d'enveloppe minimisé est $R_{\text{rente}} = \lambda - \text{tgt}$, où la cible `tgt` est construite explicitement par une branche logique :

```
bind = (x >= KAP - 1e-4).detach()
zero = (x <= SNAP_EPS).detach()
marg = p.detach() - beta*Lam.detach() - COST
tgt = torch.where(bind | zero, delta*lam2d, marg) # tgt pour target
tgt = torch.clamp(tgt + feedback.detach(), min=0.0)
R_rente = lam - tgt
```

Ces lignes servent à deux impératifs architecturaux :

1. L'ancrage pour éviter une divergence. Imposer la relation de récurrence pure ($\lambda_i = \delta\lambda'_i + \text{fb}_i$) partout génère un apprentissage autorégressif : le réseau justifie sa prédiction présente uniquement par sa propre prédiction future. S'il surestime la valeur future, il augmentera la valeur présente pour « corriger » cette surestimation, entraînant une divergence exponentielle du sentier de rente en remontant le temps. La cible force alors un ancrage physique en régime intérieur. Le tenseur `tgt` est ramené égal à la réalité `marg` ($p - \beta\Lambda_i - c_i$) (correct algébriquement par la condition du premier ordre). Ce n'est que sur les frontières de capacité (`bind`) ou d'extinction (`zero`), où `marg` est faussé par les multiplicateurs KKT, que l'algorithme bascule impérativement sur l'anticipation neuronale pure `delta*lam2d` ($\delta\lambda'_i$).

2. Le verrouillage de l'erreur par `.detach()`. Ce schéma relève du semi-gradient. En gelant le graphe de calcul de toutes les composantes de la cible (`p`, `Lam`, `lam2d`, `feedback`), l'opérateur `.detach()` impose au réseau de traiter son environnement physique courant et futur comme une donnée exogène. Sans ce verrou, la rétropropagation remonterait à travers la cible : l'optimiseur choisirait la voie de moindre résistance et déformerait violemment les extractions physiques actuelles (par exemple en faisant chuter le prix) uniquement pour dissimuler son erreur de prédiction sur λ .

2.6 Référence analytique et protocole de validation

L'oracle en boucle ouverte. On ne peut évaluer cette architecture que si l'on dispose, sur des configurations suffisamment simples, d'une solution que l'on sait exacte. Un solveur analytique,

que nous appellerons l'*oracle*, calcule à cette fin l'équilibre en boucle ouverte pour tout état initial et tout horizon résiduel, à N producteurs, coûts hétérogènes, capacités et structure de coalitions arbitraires. Il fonctionne en trois boucles imbriquées, la première étant une itération de meilleures réponses virtuelles projetées, utilisant ainsi l'argument théorique établi en §1.2.2 pour contourner l'explosion combinatoire des 3^N configurations de régimes possibles par période. La deuxième boucle est une dichotomie sur les rentes, la troisième une itération sur les rentes. Son coût est polynomial, de l'ordre de $O(N^3T)$ opérations scalaires par balayage, ce qui autorise les appels répétés de la partie III suivante. Le détail algorithmique est renvoyé en annexe B.

Une réserve importante sur cet algorithme est la suivante : les rentes μ_i entre producteurs ne sont pas indépendantes, et la boucle qui les calcule par itérations n'a pas de garantie mathématique de convergence. Les configurations non convergées sont écartées des mesures de la partie III. C'est cette limite, et non le coût de calcul, qui plafonne l'utilisation de l'oracle à $N \leq 6$.

Ce que l'on exige du réseau. Tant que le terme de feedback est désactivé, le réseau résout le même problème que l'oracle, et l'on exige qu'il le reproduise. C'est une condition *sine qua non* : si le solveur ne retrouve pas une solution que l'on sait exacte, on ne peut pas lui faire confiance là où cette solution n'existe plus. Trois métriques sont retenues : l'erreur sur le sentier de prix, le bon déroulement de la fonction valeur hors du sentier d'entraînement, et l'erreur sur la politique évaluée en des états tirés uniformément, c'est-à-dire là où le réseau doit réellement interpoler.

Vérifier un équilibre sans vérité analytique. Une fois le feedback activé, l'oracle cesse d'être l'équilibre et plus aucune solution analytique n'existe à cause du fléau de la dimension. Il ne nous reste donc que des tests de cohérence. Le principal est le test de la déviation : un profil de stratégies est un équilibre si et seulement si aucun joueur ne gagne à s'écarter une fois avant de reprendre sa politique. On perturbe donc l'extraction d'un producteur à une date donnée, puis on laisse le jeu se poursuivre selon deux conventions : les rivaux figés sur leur trajectoire de référence (cadre de la boucle ouverte), ou les rivaux passant par leur politique markovienne $\sigma_k(S)$ et répondant à l'état effectivement atteint. On compare ensuite les gains obtenus. Le premier doit être nul si le réseau a appris un équilibre en boucle ouverte, le second s'il a appris un équilibre markovien ; leur écart mesure la divergence entre les deux concepts sans recourir ni à l'oracle ni à une grille. Le protocole complet figure en annexe C.

Ce test n'a rien eu à départager : sa continuation markovienne passe par les politiques du réseau, donc par la Jacobienne croisée, que la partie III montre non identifiée. Les deux continuations sont alors indiscernables. L'outil reste valable pour un solveur qui estimerait ce terme.

3 Partie III — Résultats et diagnostics

Tous les chiffres qui suivent portent sur des variables fictives (stocks, capacités, coûts), visant à calibrer des modèles plutôt que produire des résultats empiriques. Rien ici ne prétend décrire le marché pétrolier réel.

3.1 Validation du réseau en boucle ouverte

Le réseau identifie l'équilibre en boucle ouverte avec une précision satisfaisante. L'erreur maximale sur le prix vaut $1,13 \times 10^{-2}$, mesurée sur les régimes intérieurs, là où le réseau doit interpoler et où il est donc en situation la plus défavorable. L'essentiel de cet écart vient de l'accumulation d'une imprécision locale d'environ 10^{-3} par pas de temps. La fonction valeur est bien identifiée, à 0,34 % sur 128 états tirés hors du sentier d'entraînement, et l'erreur sur la politique en régime intérieur est de l'ordre de 4 %. Ces chiffres sont obtenus sur des états volontairement

uniformes dans la boîte, comme l'exige l'identification d'un équilibre markovien (§2.3) ; ils sont donc pessimistes par rapport à ce qu'on mesurerait sur le seul sentier d'équilibre.




Figure 1: Validation du réseau contre l'oracle en boucle ouverte, configuration cartel-frange. Trait noir plein : oracle. Trait rouge tireté : réseau. **Ligne du haut**, extractions du cartel x_t^c et de la frange x_t^f . **Ligne du milieu**, sentier de prix p_t et erreur relative commise sur ce prix, en échelle logarithmique. **En bas**, marge stratégique déflatée $h_t/(1+r)^t$ du cartel. Les bandes orange marquent les quatre dates des kinks, communes à tous les panneaux. Ce sont les bascules de régime, saturation de la capacité, extinction ou entrée en régime intérieur, c'est-à-dire les points où la politique d'équilibre a une rupture de pente que le réseau, lisse, a du mal à reproduire. Ailleurs l'accord est bon. Le panneau du bas isole la loi de Hotelling : en régime intérieur (points rouges) elle impose un plateau, estimé à 12,84 contre 12,82 pour l'oracle (pointillés verts), soit 0,16 % d'écart. La forme du reste de la courbe se lit régime par régime. Quand aucun producteur n'est intérieur (les deux à κ jusqu'à $t = 6$, puis la frange éteinte de $t = 21$ à $t = 27$), l'offre est constante, donc le prix aussi : le numérateur est figé et la courbe décroît en $(1+r)^{-t}$. Ces deux décroissances sont visuellement bien parallèles. Entre elles, la frange intérieure fixe le prix par sa propre règle de Hotelling, $p_t = c_f + \mu_f(1+r)^t$, d'où $\mu_f - (\beta\kappa_c + c_c - c_f)/(1+r)^t$: la courbe remonte vers la rente de la frange, le second terme constant s'effaçant sous la déflation. Le cartel devient intérieur à $t = 28$ et sa marge s'égale alors à sa propre rente, d'où le plateau ; elle lui est partout supérieure avant, ce qui est la définition d'une capacité liante. La courbe s'éteint enfin à l'épuisement du cartel, l'ancrage terminal la ramenant à zéro. Le décrochage du plateau rouge en fin d'horizon est un artefact de l'activation `softplus`, comme discuté avec l'architecture plus haut : strictement positive, elle rend plus difficile une extraction exactement nulle, étale l'extinction sur quelques périodes et déprime la marge terminale. On note aussi un artefact lié au kink en $t = 20$. Sur ce calibrage, le terme de feedback est désactivé, ce qui permet à l'oracle de servir de référence.

Le solveur reproduit donc la dynamique d'une solution en boucle ouverte et contrôle correctement le co-état. C'était la condition à remplir avant d'ajouter la couche markovienne. Mais c'est là que l'architecture échoue, l'équilibre en boucle fermée n'ayant pas été identifié. Aucune entrée hors-diagonale de la Jacobienne croisée $\partial x_k / \partial S_i$ n'est estimée correctement, alors que ce sont ces dérivées qui portent toute l'externalité stratégique. La suite de cette section explique pourquoi.

3.2 L'échec d'identification de la Jacobienne

3.2.1 Ce qui a été tenté

La voie directe consiste à lire $\partial x_k / \partial S_i$ par différentiation automatique de la tête politique. Elle fonctionne sur la diagonale, où les projections de l'architecture fixent la dérivée dans les régimes de coin, et échoue hors diagonale, où rien ne la contraint.

Plusieurs corrections ont été essayées, toutes bloquées par l'un de deux obstacles.

Les résidus supplémentaires conçus pour contraindre directement la Jacobienne se sont révélés dégénérés : ils admettent plusieurs solutions, dont une seule est la bonne, et le réseau paresseux prend systématiquement la plus facile. Il ne corrige pas la Jacobienne, il déplace sa politique vers un régime où le résidu s'annule tout seul. L'équation est alors vérifiée sans être résolue.

Les autres routes reviennent toutes à obtenir la Jacobienne en dérivant une sortie du réseau autre que la politique, en exploitant les relations d'équilibre qui les lient. Mais ce sont déjà des approximations, et dériver une approximation la dégrade encore d'un ordre. Czarnecki et al. [6] établissent d'ailleurs qu'un réseau n'apprend correctement ses dérivées que si celles-ci sont explicitement supervisées, ce qui est exactement ce dont on ne dispose pas ici.

Ces deux obstacles ont une cause commune, que la mesure suivante rend visible.

3.2.2 Le rapport signal sur bruit

Le signal est la variation d'extraction du producteur k provoquée par une perturbation du stock du producteur i , à l'échelle sur laquelle le réseau est effectivement échantillonné, soit l'écart-type σ_i du bruit d'échantillonnage : il vaut $|\partial x_k / \partial S_i| \cdot \sigma_i$. Le bruit est l'erreur du réseau sur la politique elle-même, 0,94 baril en médiane hors des trajectoires d'entraînement.

Le signal médian de la Jacobienne, *calculé avec l'oracle dans la section suivante*, vaut 0,246 baril contre un bruit de 0,94 : la quantité qu'on veut mesurer est presque quatre fois plus petite que l'erreur déjà commise sur la grandeur dont elle est la dérivée. Sur les dix couples (t, i, k) examinés, l'erreur relative sur $\partial x_k / \partial S_i$ vaut 99,5 % en médiane et ne descend jamais sous 34 %, y compris là où le signal est le plus fort. Aucune repondération de la perte ne peut renverser cela, puisque l'on amplifierait le signal et le bruit dans les mêmes proportions.

Le contraste avec le gradient de la valeur confirme le diagnostic : les deux objets sont des dérivées croisées produites par le même graphe de différentiation, mais le gradient de valeur est d'ordre 10 dans les unités du problème contre 10^{-2} pour la Jacobienne hors-diagonale, et le réseau apprend le premier sans difficulté. Ce n'est donc pas la différentiation qui échoue, c'est l'échelle.

On en tire un critère de faisabilité : si $|\partial x_k / \partial S_i| \cdot \sigma$ est inférieur à la précision qu'on peut espérer sur la politique, l'objet n'est pas apprenable, et sur ce calibrage il ne l'est pas. Il faudrait gagner deux ordres de grandeur sur la politique pour mesurer un terme dont on ignore encore l'importance économique. Son importance économique constitue la suite du rapport : puisque le réseau ne peut pas produire le terme markovien, il faut l'obtenir autrement, ne serait-ce que pour savoir s'il valait la peine d'être cherché.

3.3 Mesurer le terme markovien sans réseau

On évalue le terme markovien le long du sentier en boucle ouverte, ce qui ne demande que l'oracle et peut paraître contre-intuitif. On justifie cette approche dans la suite.

3.3.1 Justification par le théorème de l'enveloppe

Soit σ^* le profil d'équilibre en boucle ouverte. Par définition, σ_i^* maximise la valeur de i face à σ_{-i}^* , d'où $\nabla_{\sigma_i} V_i(\sigma^*) = 0$. En notant $\sigma^{\text{CL}} = \sigma^* + \epsilon \tilde{\sigma}$ le profil markovien, où ϵ mesure l'intensité du canal de feedback, le développement de Taylor donne

$$V_i(\sigma^{\text{CL}}) = V_i(\sigma^*) + \epsilon \left[\underbrace{\nabla_{\sigma_i} V_i \cdot \tilde{\sigma}_i}_{=0} + \nabla_{\sigma_{-i}} V_i \cdot \tilde{\sigma}_{-i} \right] + \mathcal{O}(\epsilon^2).$$

Le premier terme du crochet s'annule : le producteur ayant déjà optimisé sa propre trajectoire, une déviation marginale de celle-ci n'a qu'un effet du second ordre (c'est le théorème de l'enveloppe). Évaluer le terme markovien sur un sentier qui n'est pas markovien est donc légitime au premier ordre, l'erreur sur la trajectoire étant repoussée au second.

3.3.2 Protocole

On se place à une date t_0 et on lit le vecteur de stocks $S(t_0)$ sur le sentier de référence. On perturbe le stock d'un seul producteur j , symétriquement,

$$S_j^\pm = S(t_0) \pm \varepsilon_j e_j,$$

et l'on résout l'oracle deux fois de plus sur l'horizon résiduel. La décision en t_0 donne la dérivée recherchée,

$$\left. \frac{\partial x_k}{\partial S_j} \right|_{t_0} \simeq \frac{x_k^+(t_0) - x_k^-(t_0)}{2\varepsilon_j},$$

et la somme actualisée des profits sur l'horizon résiduel donne l'autre facteur du feedback,

$$\left. \frac{\partial V_i}{\partial S_j} \right|_{t_0} \simeq \frac{1}{2\varepsilon_j} \left[\sum_{s \geq t_0} \delta^{s-t_0} (p_s^+ - c_i) x_{is}^+ - \sum_{s \geq t_0} \delta^{s-t_0} (p_s^- - c_i) x_{is}^- \right].$$

En répétant l'opération pour chaque j , on reconstitue les deux tenseurs de la §2.3.1, ce qui donne le feedback de la date t_0 . Les contributions des différentes dates sont ensuite agrégées en valeur actualisée selon l'équation (1), ce qui donne le déplacement de la rente initiale.

Comme la rente croît au taux r , l'actualisation compense exactement la croissance : $\delta^t \text{fb}_i(t) = (\text{fb}_i(t)/\lambda_i(t))\mu_i$, et chaque date intérieure contribue du même ordre de grandeur, sans atténuation. Une vingtaine de dates à 0,3% produisent ainsi quelques pourcents sur μ . C'est la seule raison pour laquelle un terme instantané aussi faible finit par se voir.

3.3.3 Le choix du pas

La différence est centrée : les termes pairs du développement s'annulent, dont la courbure, et l'erreur de troncature passe de $\mathcal{O}(\varepsilon)$ à $\mathcal{O}(\varepsilon^2)$ tant que la perturbation reste dans un même régime. Le pas est par ailleurs borné par une fraction du stock disponible, un stock négatif n'ayant pas de sens.

Le réglage de ε est contraint des deux côtés : trop petit, il place la différence des deux résolutions sous le seuil de précision de l'oracle, et le numérateur devient du bruit amplifié par la division. Trop grand, il fait sortir la perturbation du régime dans lequel on cherche à dériver : la politique

étant linéaire par morceaux avec des ruptures aux bascules, on mesure alors une pente moyenne entre deux régimes.

Cette construction a une limite plus fondamentale encore : elle ne cartographie pas l'ensemble des déviations possibles ; le faire reviendrait à explorer l'espace d'états et ramènerait le fléau de la dimension que les réseaux devaient contourner. Elle évalue une tangente en un petit nombre de points. C'est ce qui la rend praticable et ce qui borne sa portée : elle donne une idée de combien la solution en boucle ouverte se trompe et dans quel sens, pas la trajectoire markovienne elle-même.

3.4 Quand le terme markovien s'annule

Deux configurations précises annulent exactement le terme markovien.

3.4.1 Saturation des capacités

Proposition 1 (Extinction du terme de feedback sous saturation). *Si le producteur k est saturé à la date t , alors $\partial x_k / \partial S_i(t) = 0$ pour tout i . Si le producteur i est saturé à toutes ses dates actives, alors $\partial x_k / \partial S_i(t) = 0$ pour tout k et tout t .*

La première assertion découle de la disjonction établie en partie I : en régime saturé la solution vaut κ_k quelles que soient les valeurs voisines des stocks, donc sa dérivée est nulle. La seconde tient parce que S_i n'affecte le prix qu'à travers sa propre extraction ; si celle-ci est plafonnée partout où i produit, aucun rival ne peut y réagir.

Le terme $fb_i(t)$ est donc nul dès qu'un seul des deux producteurs concernés bute sur une borne. Un producteur qui tourne à pleine capacité n'est plus une variable stratégique : il ne peut ni réagir, ni faire réagir. La divergence entre les deux concepts d'équilibre ne peut apparaître que sur les dates où au moins deux producteurs stratégiques sont simultanément intérieurs, ce qui justifie de restreindre le balayage du protocole précédent à ces dates. C'est aussi pourquoi on aurait pu activer le terme de feedback dans la configuration de la figure 1 sans pour autant en changer les résultats.

3.4.2 Symétrie parfaite

Proposition 2 (Extinction du feedback sous symétrie parfaite). *Sur un marché où tous les producteurs sont identiques, la politique d'un producteur est localement insensible aux réserves de ses rivaux : $\partial x_k / \partial S_i = 0$ pour tout $k \neq i$. Le terme de feedback s'annule, et l'équilibre en boucle fermée coïncide avec l'équilibre en boucle ouverte.*


Donnons un baril supplémentaire au producteur 0 : il extrait un peu plus, donc le sentier de prix baisse légèrement. Un rival subit alors deux effets de sens contraire. Le prix plus bas réduit sa marge courante et l'incite à extraire moins ; mais ce même prix plus bas déprécie son propre stock, sa rente de rareté diminue, et une rente plus faible l'incite à extraire davantage. Sous symétrie parfaite les deux effets se compensent exactement, et son extraction ne bouge pas : seul son profit baisse.

Ce cas limite, bien que purement théorique, montre que l'externalité stratégique naît de la brisure de symétrie (hétérogénéité des coûts ou des réserves). Tout repose en effet sur le partage d'un même calendrier de régimes, que la symétrie garantit. C'est précisément ce que l'hétérogénéité détruit : les marges diffèrent, les dates de bascule se désynchronisent, les deux effets ne portent plus sur les mêmes dates ni sur les mêmes montants, et le terme de feedback réapparaît.

3.5 Hétérogénéité et fragmentation

3.5.1 L'hétérogénéité engendre le terme markovien

Pour isoler l'effet de l'hétérogénéité, on construit une famille de calibrations où le stock et la capacité sont constants, seuls les coûts s'étalant sur une plage croissante. Les producteurs sont des oligopolistes isolés (la ligne i de A est e_i , le vecteur de base). Le protocole de la §3.3 est appliqué à chaque calibration. On rapporte le déplacement de rente moyen par date sondée, et non le cumul : celui-ci dépend de la largeur de la fenêtre intérieure, qui varie avec les régimes, et n'est donc pas comparable d'une calibration à l'autre.



À écart de coût nul, le déplacement vaut 0,00000 % pour $N = 3$, 0,00004 % pour $N = 4$ et 0,003 % pour $N = 6$. Les trois sont au plancher de bruit, ce qui confirme l'annulation sous symétrie. Dès que les coûts diffèrent, le terme apparaît et croît avec l'écart : à $N = 3$ la moyenne passe de 0,022 % pour un écart faible à 0,123 % pour un écart fort, soit un facteur 5,7, contre 4,7 à $N = 4$ et 3,0 à $N = 6$. La corrélation entre écart de coût et déplacement vaut respectivement 0,87, 0,77 et 0,56.

Le nuage est dispersé, mais ce n'est pas du bruit numérique : toutes les résolutions ont convergé à 10^{-11} . Les oscillations viennent des bascules de régime, qui déplacent les dates sur lesquelles le terme se cumule d'un calibrage à l'autre.

L'ordre de grandeur éclaire rétrospectivement l'échec du réseau. Le cumul sur la rente ne dépasse pas 5 % et la moyenne par date reste sous 0,21 %, contre un plancher de bruit du solveur à 1,1 %. Le signal cherché est donc intrinsèquement faible, indépendamment de la qualité de l'apprentissage. On peut aller plus loin : il n'existe aucune calibration de cette famille où le réseau aurait pu réussir. Le PINN a été entraîné sur des coûts, capacités et stocks fixés, mais rendre le calibrage plus hétérogène pour augmenter le signal ne l'aurait pas amené au-dessus du bruit, et augmenter N le fait décroître. Le choix de calibrage n'a donc pas été le mauvais choix ; il n'y avait pas de bon choix.

3.5.2 La fragmentation dilue le terme

Les trois séries permettent une seconde lecture, en comparant les niveaux à hétérogénéité comparable. Le déplacement moyen sur les écarts non nuls vaut 0,080 % à $N = 3$, 0,061 % à $N = 4$ et 0,044 % à $N = 6$.

	rapport mesuré	$1/N$
$N = 3 \rightarrow N = 4$	1,30	1,33
$N = 3 \rightarrow N = 6$	1,80	2,00

Ces deux rapports sont compatibles avec une décroissance en $1/N$, sans pour autant l'établir. C'est le sens de variation qui est solide. La pente de la relation entre hétérogénéité et déplacement s'affaïsse d'ailleurs elle aussi, passant de 0,0122 à 0,0073 puis 0,0037 point de pourcentage par unité de coût : la **fragmentation** (l'ajout de joueurs) abaisse le niveau du terme et atténue en même temps sa sensibilité à l'asymétrie. L'externalité stratégique se dilue dans le nombre, l'incitation à réagir au stock d'un rival spécifique s'effondre, et tout avantage de coût perd de son pouvoir de dissuasion.

Discussion et conclusion

Ce travail devait produire un solveur markovien à N producteurs, pour évaluer les équilibres d'extraction sous un grand nombre de structures de blocs. Il n'y parvient pas, mais aboutit à deux choses. La première est de savoir pourquoi les PINNs échouent sur ce problème. La seconde est une mesure du terme markovien, obtenue sans eux, par différences finies sur l'oracle.

Ce que l'échec du réseau montre

Le signal de réaction croisée recherché vaut environ 0,25 baril en médiane sur l'échelle d'échantillonnage, contre un bruit d'approximation de la politique de 0,94 baril. Avec un tel rapport, l'identification par les PINNs est impossible et ne relève pas d'un défaut de réglage : il faudrait gagner deux ordres de grandeur sur la précision de la politique, ce qui paraît hors d'atteinte. L'oracle en boucle ouverte n'a pas ce plancher, puisqu'il donne une solution exacte à la précision machine. Et maintenant que l'ordre de grandeur du signal est connu, toute méthode en boucle fermée dont le bruit d'approximation lui est supérieur peut être écartée d'emblée.

La coïncidence entre boucle ouverte et boucle fermée dans le jeu cartel-frange, avec un seul stratégique face à une frange preneuse de prix, est établie par Benchechroun et Withagen [3]. Ce travail y ajoute la contrainte de capacité, le plus souvent absente ailleurs, et l'ajout n'est pas négligeable : un producteur au plafond n'est ni acteur ni cible du canal markovien, et les marchés pétroliers opèrent une part substantielle du temps sous contrainte de capacité, comme le montre le calibrage d'Okullo et Reynès [12] sur l'OPEP et sa frange. Sur le calibrage de la figure 1, cette seule propriété suffit à annuler le terme, sans avoir besoin du théorème. La difficulté se déplace alors vers la date des bascules, qui décide si le canal est ouvert et qui dépend elle-même des stocks. Le terme markovien ne vit que sur les dates de régime intérieur, là précisément où les mesures sont les plus fragiles.

Les mesures obtenues par l'oracle en partie III ont deux limites à garder à l'esprit : ce sont des corrections au premier ordre évaluées sur le sentier en boucle ouverte, et non l'écart d'équilibre exact ; et les calibrations ne comportent que des oligopolistes isolés, à capacités et stocks identiques, avec des coûts allant de 10 à 22. Le passage à une structure avec cartels, oligopolistes et frange demande d'agréger chaque bloc en un décideur unique (en l'occurrence, agréger les cartel-listes en un cartel qui serait un seul et même agent), faute de quoi les membres ont des lignes identiques dans l'opérateur B de la partie I, qui perd son inversibilité. Une fois cette agrégation faite, le N pertinent devient le nombre de blocs, et c'est avec lui que le terme markovien devrait se diluer.

Le canal markovien ne transite que par les rentes, donc si celles-ci convergent, le terme disparaît

avec elles. La dilution observée en $1/N$ suggère

$$\sup_t \frac{|\lambda_i^{\text{CL}}(t) - \lambda_i^{\text{OL}}(t)|}{\lambda_i^{\text{OL}}(t)} \xrightarrow{N \rightarrow \infty} 0,$$

sans l'établir : trois valeurs de N ne font pas un régime asymptotique, mais c'est une intuition de convergence uniforme qui pourrait faire l'objet de futurs travaux théoriques utiles.

Ce qu'il faudrait tenter ensuite

Aucune calibration ne sauve le réseau : augmenter l'hétérogénéité pour grossir le signal ne suffit pas, et augmenter le nombre de producteurs le réduit. La tabulation d'un équilibre markovien sur grille tombe pour une raison de coût, ne survivant pas au-delà de trois agents alors qu'un graphe de structures peut en demander une vingtaine. Les briques d'architecture méritent en revanche d'être conservées : la projection géométrique des contraintes par `torch.clamp`, l'ancrage terminal, la normalisation par le facteur de croissance de Hotelling et les tests de cohérence restent utilisables pour un solveur en boucle ouverte.

La piste qui paraît la plus prometteuse est un apprentissage entièrement supervisé sur un grand nombre de solutions produites par l'oracle. Ce qui motive l'approche est le coût : une résolution analytique peut prendre quelques minutes, et il en faut une par nœud et par jeu de stocks ; un réseau approchant l'application $(S_0, c, \kappa, A) \mapsto (\mu, x, p)$ serait cher une fois seulement pour l'entraînement, puis gratuit. On obtiendrait une politique en boucle ouverte généralisée et instantanée. Une perte du type $\text{MAE} + \lambda \text{MSE}$ conviendrait, et la précision de l'approximation ne dépendrait plus que du nombre de solutions analytiques préparées dans la base de données.

Chaque nœud gagnerait par ailleurs à être annoté de sa correction markovienne, vue comme un critère de robustesse et non comme une vérité absolue. Le protocole de la §3.3 coûte $2N$ résolutions supplémentaires par date, ce qui est négligeable, et deux nœuds séparés par moins que leur correction ne peuvent pas être départagés : ils doivent être signalés comme tels plutôt que classés. Avec trois ou quatre affectations possibles par producteur (cartelliste, oligopoliste, frange, partenaire de la coalition climatique), le graphe complet compte jusqu'à 4^N nœuds, dont l'immense majorité n'a pas besoin d'être calculée ; reste à savoir lesquels écarter *a priori*, question qui n'est pas tranchée ici.

Conclusion

Le terme markovien est mesurable au premier ordre sans solveur markovien, en perturbant les stocks par différences centrées autour de l'équilibre en boucle ouverte. Les mesures montrent qu'il s'annule dès qu'un producteur sature sa capacité, qu'il naît de l'hétérogénéité des coûts, et qu'il s'atténue quand le marché se fragmente (lorsque N augmente). Sur le domaine exploré il déplace la rente de quelques pourcents au plus, soit moins que la précision qu'un réseau non supervisé peut espérer atteindre, ce qui explique rétrospectivement pourquoi la voie des PINNs ne pouvait pas aboutir : elle cherchait un signal plus petit que son propre bruit.

Une partie du travail effectué ici vise aussi à montrer que la boucle ouverte n'est pas une solution de repli ou une solution subie. Devant la faiblesse de l'intensité markovienne, c'est un choix qu'on peut largement défendre pour évaluer les politiques climatiques côté offre et la stabilité des structures de blocs. On peut de plus chiffrer la faible différence qu'aurait pu produire un jeu markovien nœud par nœud, comme le permet la méthode décrite en partie III. En définitive, le travail qui reste porte moins sur le concept d'équilibre que sur la capacité à résoudre vite un grand nombre de nœuds.

A Annexe A — Distributions

Soit f une fonction continue sur $\mathbb{R}$ dont la dérivée première f' présente un saut d'amplitude $c \neq 0$ en x_0 . Soit φ une fonction test.

Par définition de la dérivée distributionnelle :

$$\langle (f')', \varphi \rangle = -\langle f', \varphi' \rangle.$$

La décomposition de l'intégrale autour de la singularité x_0 permet d'appliquer l'intégration par parties sur les ouverts $] -\infty, x_0[$ et $]x_0, +\infty[$:

$$\langle f'', \varphi \rangle = - \int_{-\infty}^{x_0} f'(x) \varphi'(x) dx - \int_{x_0}^{+\infty} f'(x) \varphi'(x) dx.$$

Le support de φ étant compact, les termes de bord en $\pm\infty$ s'annulent. L'intégration par parties donne :

$$\begin{aligned} \langle f'', \varphi \rangle &= -[f'(x)\varphi(x)]_{-\infty}^{x_0^-} + \int_{-\infty}^{x_0} f''(x)\varphi(x) dx - [f'(x)\varphi(x)]_{x_0^+}^{+\infty} + \int_{x_0}^{+\infty} f''(x)\varphi(x) dx \\ &= -f'(x_0^-)\varphi(x_0) + f'(x_0^+)\varphi(x_0) + \int_{\mathbb{R} \setminus \{x_0\}} f''(x)\varphi(x) dx. \end{aligned}$$

Soit $g(x)$ la dérivée seconde classique définie sur $\mathbb{R} \setminus \{x_0\}$. En factorisant $\varphi(x_0)$, on a :

$$\langle f'', \varphi \rangle = \underbrace{(f'(x_0^+) - f'(x_0^-))}_c \varphi(x_0) + \int_{\mathbb{R}} g(x)\varphi(x) dx.$$

Par définition de la distribution de Dirac, $\langle \delta_{x_0}, \varphi \rangle = \varphi(x_0)$. On a donc l'égalité au sens des distributions :

$$f'' = g + c\delta_{x_0}$$

où $g(x)$ est la partie régulière et δ_{x_0} la distribution de Dirac centrée en x_0 .

Par propriété algébrique de la transformée de Fourier sur les dérivées :

$$\mathcal{F}\{f''\}(\omega) = (i\omega)^2 \hat{f}(\omega) = -\omega^2 \hat{f}(\omega).$$

Par linéarité de la transformée de Fourier appliquée à l'expression distributionnelle :

$$\mathcal{F}\{f''\}(\omega) = \mathcal{F}\{g\}(\omega) + c\mathcal{F}\{\delta_{x_0}\}(\omega) = \hat{g}(\omega) + ce^{-i\omega x_0}.$$

En égalisant les deux expressions pour isoler $\hat{f}(\omega)$:

$$\begin{aligned} -\omega^2 \hat{f}(\omega) &= \hat{g}(\omega) + ce^{-i\omega x_0} \\ \hat{f}(\omega) &= -\frac{\hat{g}(\omega)}{\omega^2} - \frac{ce^{-i\omega x_0}}{\omega^2}. \end{aligned}$$

et le terme régulier est négligeable devant le second en l'infini.

B Annexe B — L'oracle analytique en boucle ouverte

Cette annexe détaille l'algorithme résumé en §2.6. L'oracle calcule l'équilibre en boucle ouverte exact pour tout état initial et tout horizon résiduel, et s'organise en trois boucles imbriquées.

(a) Meilleures réponses projetées. À rentes fixées, chaque période devient un équilibre statique indépendant, dont la condition du premier ordre se résout coordonnée par coordonnée en projetant la solution virtuelle via le même opérateur de projection qui a servi pour la tête politique du réseau. On balaie les producteurs en mettant à jour chacun à quantités rivales figées, jusqu'au point fixe (itérations de meilleures réponses, similaire à un algorithme de Gauss-Seidel).

L'image est celle d'une descente le long d'un axe vers le fond d'un puits : tant que la variable reste libre, elle glisse vers sa meilleure réponse ; si elle percute un mur (la capacité κ_i ou la borne de positivité) l'opérateur de projection l'arrête net et la fige à cette valeur. L'algorithme poursuit alors sa descente sur les seuls axes restants. C'est ce qui permet de ne jamais énumérer l'ensemble actif : la projection le découvre au fil des balayages, alors qu'une résolution matricielle directe exigerait de tester 3^N configurations de régimes par période. C'est aussi la traduction algorithmique exacte de la disjonction de cas établie en §1.2.2.

(b) Recherche des rentes par dichotomie. À rentes rivales fixées et *sans imposer d'épuisement*, l'extraction cumulée $\sum_t x_i(t; \mu_i)$ décroît avec μ_i : une rente plus élevée renchérit le coût d'opportunité à toutes les dates, donc réduit l'extraction partout, et la décroissance est stricte tant qu'au moins une date reste en régime intérieur.

Cette monotonie permet une dichotomie sur la condition d'épuisement $\sum_t x_i = S_{i,0}$. On part de $[0, \alpha]$ (α est le choke price) : à $\mu_i = 0$ le producteur extrait sans contrainte de rareté et sur-consomme son stock, tandis qu'à $\mu_i = \alpha$ le coût d'opportunité atteint le prix de choke et l'extraction est nulle. La solution est donc encadrée, et l'écart d'épuisement change de signe entre les deux bornes. On évalue au milieu, on garde la moitié qui contient le changement de signe, et on recommence : m divisions ramènent l'intervalle à $\alpha/2^m$, soit une précision machine en une cinquantaine d'itérations.

(c) Couplage des rentes. Les μ_i ne sont pas indépendants, puisque le cumul de chaque producteur dépend des rentes des autres à travers le prix. On procède comme pour les extractions, en balayant les producteurs et en résolvant chaque rente à rentes rivales figées, jusqu'au point fixe. La différence est qu'ici rien ne garantit la convergence. L'algorithme converge en pratique jusqu'à au moins $N = 6$, c'est pour cela qu'il a été utilisé en partie III. Cet algorithme reste perfectible pour des travaux futurs.

Complexité. Un balayage complet coûte $O(N^3T)$ opérations scalaires, ramenées à $O(N^2)$ opérations vectorielles de longueur T par la vectorisation temporelle. Le décompte porte sur le balayage seul et omet le nombre d'itérations des boucles (b) et (c), mesuré plutôt que borné.

C Annexe C — Le test de déviation

Cette annexe détaille le protocole résumé en §2.6.

Construction. On déroule le réseau depuis S_0 , ce qui donne la trajectoire de référence X^{ref} et les stocks correspondants. On choisit une date t_0 et un producteur i , et l'on construit une grille de déviations ε couvrant $\pm 15\%$ de $\min(S_i(t_0), \kappa_i)$. Pour chaque valeur on impose $x_i(t_0) = X_i^{\text{ref}}(t_0) + \varepsilon$, puis on laisse le jeu se poursuivre jusqu'à l'horizon, une fois avec les rivaux figés sur leur trajectoire de référence, une fois avec les rivaux passant par leur politique $\sigma_k(S)$. On calcule dans chaque cas le profit actualisé du déviant sur l'horizon résiduel, et l'on retient le gain relatif de la meilleure déviation par rapport à $\varepsilon = 0$. Si le réseau a appris un équilibre en boucle ouverte, ce gain doit être nul dans le premier cas, où les rivaux sont figés. S'il a appris un équilibre markovien, il doit l'être dans le second, où les rivaux répondent à l'état atteint.

Note sur l'usage d'IA

L'IA a été utilisée pour polir la rédaction de certains paragraphes et pour aider au débogage du code. Les outils algorithmiques, les démonstrations, les arguments théoriques et les résultats empiriques présentés dans ce rapport sont ceux de l'auteur, qui en assume seul la responsabilité.

References

- [1] Azinovic, M., Gaegauf, L., Scheidegger, S. (2022). Deep Equilibrium Nets. *International Economic Review* 63(4), 1471–1525.
- [2] Barron, A. R. (1993). Universal approximation bounds for superpositions of a sigmoidal function. *IEEE Transactions on Information Theory* 39(3), 930–945.
- [3] Benchekroun, H., Withagen, C. (2012). On price taking behavior in a nonrenewable resource cartel–fringe game. *Games and Economic Behavior* 76(2), 355–374.
- [4] Benchekroun, H., Elgersma, S., van der Meijden, G., Withagen, C. (2026). Leadership and Commitment in Oil Markets: Market Power Meets Climate Policy. Working paper.
- [5] Coulomb, R., Henriët, F., Reitzmann, L. (2025). 'Bad' Oil, 'Worse' Oil and Carbon Misallocation. Working paper.
- [6] Czarnecki, W. M., Osindero, S., Jaderberg, M., Świrszcz, G., Pascanu, R. (2017). Sobolev Training for Neural Networks. *NeurIPS*.
- [7] De Cannière, C. (2025). Pump it? Market Power and the Energy Transition in the Global Oil Market. Job Market Paper, KU Leuven.
- [8] Hotelling, H. (1931). The Economics of Exhaustible Resources. *Journal of Political Economy* 39(2), 137–175.
- [9] Jean, L. (2026). Essays on Climate Policy and Heterogeneous Oil Resources. Thèse de doctorat, Paris School of Economics.
- [10] Kingma, D. P., Ba, J. (2015). Adam: A Method for Stochastic Optimization. *ICLR*.
- [11] Krishnapriyan, A., Gholami, A., Zhe, S., Kirby, R., Mahoney, M. W. (2021). Characterizing possible failure modes in physics-informed neural networks. *NeurIPS*.
- [12] Okullo, S. J., Reynès, F. (2016). Imperfect cartelization in OPEC. *Energy Economics* 60, 333–344.
- [13] Raissi, M., Perdikaris, P., Karniadakis, G. E. (2019). Physics-informed neural networks: a deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics* 378, 686–707.
- [14] Salant, S. W. (1976). Exhaustible Resources and Industrial Structure: A Nash-Cournot Approach to the World Oil Market. *Journal of Political Economy* 84(5), 1079–1093.
- [15] Wang, S., Teng, Y., Perdikaris, P. (2021). Understanding and mitigating gradient flow pathologies in physics-informed neural networks. *SIAM Journal on Scientific Computing* 43(5), A3055–A3081.